



L'intelligence artificielle en bibliothèque

Décembre 2025



Plan

Introduction : une petite histoire de l'IA — 20 mn

- A. Apprentissage machine — 20 mn
- B. Evaluation des performances — 15 mn + atelier 10 mn
- C. Apprentissage machine (suite) — 45 mn + atelier 15 mn

3 h

D. Comprendre les images — 45 mn

E. Comprendre le langage — 45 mn

F. Modèles de langue — 45 mn

G. LLM et VLM — 45 mn

H. OCR, HTR — 15 mn

I. Ingénierie de l'IA, méthodes — 30 mn

J. Ingénierie de l'IA, pratiques — 30 mn

5 h

Plan

Cas d'usage pour le patrimoine — 45 mn

L'IA du quotidien — 15 mn


Stratégies d'organisation : l'exemple de la BnF — 15 mn

Enjeux éthiques et sociaux — 15 mn

1 h 30

Ateliers

https://github.com/altomator/Formation_IA



Une petite histoire de l'IA : d'Alan Turing aux grands modèles de langue




Voir aussi CNRS-Fidle :
[Qu'est-ce que l'IA](#)
[Histoire de l'IA](#)

Qu'est-ce que l'intelligence artificielle ?

- Alan Turing (1950) : « Les machines peuvent-elles penser ? » ou le Test de Turing
⇒ **Une définition philosophique** : une machine est “intelligente” lorsqu’elle peut imiter un comportement humain de manière indiscernable (aux yeux d’un humain).
 - Définition du Parlement Européen (reprise par la norme ISO/IEC 42001:2023 *Information technology - Artificial intelligence Management System*):
⇒ **Une définition réglementaire** : “Possibilité pour une machine de reproduire des comportements liés aux humains, tels que le raisonnement, la planification et la créativité.”
 - Open AI (2025) : Charte publique “Notre vision de l’IAG du futur”
⇒ **Une définition idéologique** : “Notre mission est de nous assurer que l’intelligence artificielle générale, un système d’IA plus intelligent que les êtres humains, ait un impact positif sur l’ensemble de l’humanité.”
- ⇒ En pratique : L’IA comme champ disciplinaire de recherche et d’applications

Alan Turing



Le test de Turing, [Wikipedia](#). Jeu de l'imitation. "A et B sont respectivement un ordinateur programmé pour se faire passer pour un humain et un joueur humain. Le joueur C, l'interrogateur, doit déterminer lequel de ces joueurs est un ordinateur. L'interrogateur est limité à des questions écrites."

« Les machines peuvent-elles penser ? »

Question sans réponse : ni "machine", ni "penser" ne sont clairement définis.

- *machine* : machine de Turing (ordinateur)
- *penser* : une machine présentant un comportement indiscernable de celui d'un être humain

« Computing Machinery and Intelligence », Alan Turing, *Mind* (1950)



Ce test est aujourd'hui surmonté par les chatbots.

« Se demander si un ordinateur sait penser est aussi intéressant que se demander si un sous-marin sait nager », Edsger Dijkstra, 1984

Le neurone artificiel


Analogie entre les neurones biologiques et un modèle computationnel : « Si le neurone est suffisamment excité, il atteint un potentiel d'activation suffisant. »

“The Formal Neuron”, Mc Culloch & Pitts (1943)



Le Perceptron : un neurone artificiel “concret”

- Le Perceptron est un classificateur binaire capable d'apprendre à partir des données en ajustant les poids de ses entrées via des algorithmes d'apprentissage
- À la base de l'apprentissage machine et des réseaux neuronaux (à propagation avant)



Frank Rosenblatt (1958),
M. Minsky and S. Papert
(1969)



L'IA symbolique




Fig. 1—Relationships between E, P, and Tx.

Le Logic Theorist est un programme informatique écrit en 1955 et 1956 par Allen Newell, Herbert Simon et Cliff Shaw. Il a été conçu pour reproduire les compétences de résolution de problèmes d'un être humain et est considéré comme le premier programme d'intelligence artificielle. Il a été capable de prouver 38 des 52 théorèmes des *Principia Mathematica* de A.N Whitehead et Bertrand Russell (1910-1913).

- Ensemble des méthodes d'intelligence artificielle reposant sur la logique et des représentations symboliques de haut niveau
- Programmation logique, règles de production, réseaux sémantiques ou les *frames* (Marvin Minsky, 1974).
- A conduit aux systèmes experts, calcul symbolique, démonstrateurs de théorèmes automatisés, ontologies, web sémantique...
- Approche dominante de 1950 à 1990

Voir aussi *Histoire de l'IA*, chapitre 6, F. Fürst

L'apprentissage machine




- Arthur Samuel : pionnier du concept de l'apprentissage machine (*machine learning*). Il développe un programme informatique capable d'améliorer sa performance au jeu de dames au fil du temps.
- Apprentissage via *l'expérience* (enregistrement des coups + gains consécutifs)

Arthur Samuel (1956)

<https://www.ibm.com/history/early-games>

Les systèmes experts



```

Patient's name: MARCUS BLOICE
Sex: MALE
Age: 30
Culture: 1
From what site was specimen CULTURE-1 taken? F
Must be one of: blood

From what site was specimen CULTURE-1 taken? BLOOD
How many days ago was this culture (CULTURE-1) obtained? F
Must be a number

How many days ago was this culture (CULTURE-1) obtained? 3
-----
Enter the identity ( genus ) of ORGANISM-1? NOV
Why is the value of identity being asked for?
Identity is one of the root parameters

Enter the identity ( genus ) of ORGANISM-1? F
Must be one of: pseudomonas, klebsiella, enteric, staphylo, bacillus, strepto


Enter the identity ( genus ) of ORGANISM-1? ENTER
```

Mycin (identification d'infections bactériennes), 1970

- Reproduire le processus cognitif d'un expert
- Extraire la connaissance et l'expérience d'un expert sous forme de règles logiques. Pour la traduction, règles de grammaire et de syntaxe
- Connaissances dans un domaine donné + formalisation des raisonnements des spécialistes qui lient ces connaissances -> décision, diagnostic, etc.

Exemple de règle (DENDRAL) : "Si le spectre de la molécule présente deux pics x1 et x2 tels que $x1 - x2 = M + 28$ et $x1 - 28$ est un pic élevé et $x2 - 28$ est un pic élevé et au moins l'un des pics x1 et x2 est élevé Alors la molécule contient un groupe cétone"

Réseaux neuronaux convolutifs : comprendre les images



Convolutional Network Demo from 1989 [restored version]

- Objectif : lire des codes postaux manuscrits
- Algorithme de rétropropagation (Rumelhart, 1986) + réseau neuronal multicouche
- Essor de l'apprentissage profond (réseaux de neurones artificiels multicouches)

Yann LeCun, AT&T Bell Labs (1989)


Les premières IA grand public



Système de traduction d'Altavista, à la fin des années 1990 (technologie Systran)

- Années 90, développement de multiples applications : traitement de la donnée, du texte, des images : chatbot A.L.I.C.E., Deep Blue d'IBM, Furby
- A partir des années 2000, généralisation de l'apprentissage machine : IBM Watson, Siri, Kismet, AlphaGo de Google DeepMind


Support Vector Machine (SVM)



- Une machine à vecteurs de support est un algorithme d'apprentissage supervisé utilisé pour la classification
- Comment trouver la meilleure frontière (hyperplan) qui sépare deux classes de données ?
- SVM cherche celle qui maximise la marge entre les classes (distance entre les points les plus proches de la frontière)
- Approche mathématique formelle (preuve)
- Aussi efficace que les réseaux de neurones

Vladimir Vapnik, 1995

AlexNet (2012)




- 30 septembre 2012 : un réseau neuronal convolutif (CNN) appelé AlexNet remporte la compétition ImageNet 2012 (de très loin).
- 2 doctorants de G.E. Hinton
- Contre des approches type SVM, ils démontrent que les réseaux de neurones fonctionnent mieux (preuve empirique)



ImageNet Classification with Deep Convolutional Neural Networks, Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton, 2012

Bataille connexionnisme/symbolique

Source : [Cairn](#)



Après AlexNet : la domination du connexionnisme




De Turing à ChatGPT

Ces théories/technologies existent depuis les années 1950, mais c'est dans les années 2000 qu'elles se sont développées grâce à :

1. L'augmentation des capacités de calcul (cartes spécialisées, GPU, construites pour le jeu vidéo).
2. Modèles et algorithmes d'apprentissage profond basés sur des réseaux de neurones artificiels.
3. Disponibilité de grande quantité de données pour l'entraînement.

Training compute of notable models



Evolution de la puissance de calcul nécessaire à l'entraînement




GPU NVIDIA L40, 21 TFLOPS (21 billions d'opérations par seconde)

L'importance des données


En 20 ans, on passe des systèmes experts à base de règles aux modèles générés par apprentissage, qui infèrent sur une grande quantité de données les décisions les plus probables.

Cette évolution pose la question du coût (utilisation massive de données et d'architectures de calcul) et donc des risques de monopole (seuls certains grands acteurs peuvent rester compétitifs dans cette course).



1 zettaoctet = 10^{21} octets = 1 milliard de To

Machines probabilistes ?



L'apprentissage machine est une approche **probabiliste**, rendue possible par la conjonction :
puissance de calcul + données + modèles statistiques

On dit qu'un modèle est "probabiliste" car il traite l'incertitude, prédit des distributions de probabilité, et repose sur des concepts probabilistes pour son apprentissage et son interprétation. Même si le modèle produit un résultat déterministe à l'issue (associé à un degré de confiance), en interne il fonctionne de manière probabiliste.

Lorsqu'on entraîne un modèle d'IA, il observe des exemples (des données numériques, des images de chats et de chiens avec leurs labels), mais il ne mémorise pas chaque exemple ni ne le "comprend". Il apprend des tendances statistiques dans les données.

Combien d'intelligences artificielles ?

On peut distinguer (schématiquement) trois types d'IA :

IA générale ou forte : machine capable de résoudre n'importe quelle tâche cognitive comme un humain. Pour certains, cela serait possible et ChatGPT serait une première forme de ce type d'IA

IA étroite ou faible : machine capable de réaliser une seule tâche de manière quasi parfaite (par ex. OCR).

Super IA : IA dotée d'une conscience propre.
Scénario de science-fiction...




Des IA et des systèmes d'IA

L'apprentissage machine appliquée aux **images**, la vision assistée par ordinateur ou "computer vision" : conduite autonome, reconnaissance faciale, robotique, santé, média et documentation (OCR, HTR, etc.), etc.

L'apprentissage machine appliqué au **langage** (TNL, TAL ou NLP) : analyser, comprendre et extraire des informations à partir de données textuelles => les grands modèles de langue.

Les **IA génératives**, des modèles capables de générer texte, son, images, vidéo à partir d'une description textuelle (*prompt*) ou d'autres données sonores, visuelles, etc. : création artistique, assistant bureautique, pilotage, etc. => agents conversationnels.


Des **assistants embarqués** dans d'autres environnements ou des progiciels spécifiques : applications d'e-commerce, média, énergie, informatique, "nouveaux" moteurs de recherche du web, etc.



Les grands modèles de langue (LLM)

Modèles d'intelligence artificielle utilisés pour modéliser et traiter le langage humain. Ils sont appelés « **grands** » parce que ces types de modèles sont entraînés sur de grands ensembles textuels provenant de différentes sources et sont constitués de centaines de millions à des milliards de paramètres (réseau de neurones profond) qui définissent le comportement du modèle. Leurs paramètres affectent les capacités langagières et d'acquisition de connaissances du modèle.

Par exemple, GPT-3 a été formé avec environ 175 milliards de paramètres.
Son concurrent, LLaMA 2, a été entraîné avec 70 milliards de paramètres.
Un modèle récent DeepSeeck serait entraîné avec 671 milliards de paramètres.
GPT 4.5 : > 1000 milliards ?



<https://informationisbeautiful.net/visualizations/the-rise-of-generative-ai-large-language-models-llms-like-chatgpt/>



A. Apprentissage machine

Théorie, vocabulaire

Les disciplines de l'IA

Approche symbolique (systèmes experts)


Approche probabiliste

Apprentissage machine : champ de recherche qui élabore des modèles probabilistes capables d'apprendre des motifs à partir de données, puis d'appliquer leur apprentissage sur de nouvelles données.

Apprentissage profond (approche connexionniste) : modèles basés sur multiples couches de réseaux de neurone (plusieurs couches de nœuds interconnectés).

IA neuro-symbolique

Systèmes multi-agents



Algorithmes et modèles ?

ALGORITHME

Série d'instructions logiques permettant de résoudre un problème ou d'effectuer une tâche. Plus formellement, un algorithme est une **séquence finie et non ambiguë d'actions** qui produit un résultat à partir de données et/ou d'interactions avec l'utilisateur.

Humain : conçoit l'algorithme, le code

Usage : exécuter le programme résultant du code

MODÈLE

Représente ce qui a été appris à partir des données grâce à l'application d'une **méthode d'apprentissage**. Le modèle est essentiellement l'aspect « appris » de l'apprentissage, encapsulant les connaissances ou les motifs appris lors du processus d'apprentissage. Le modèle sera utilisé pour faire des prédictions sur de nouvelles données.

Humain : prépare les données, choisit la méthode d'apprentissage

Usage : appliquer le modèle sur de nouvelles données

Apprendre par l'exemple

Selon le problème qu'on veut résoudre et la nature des données, on choisit la **méthode d'apprentissage** et l'**algorithme d'apprentissage** qui l'opérationnalise.

Apprentissage supervisé (A)	Apprentissage non supervisé (B)	Apprentissage semi-supervisé	Apprentissage par renforcement
Les données sont <u>annotées</u> et l'algorithme doit apprendre un modèle	Les données <u>ne sont pas annotées</u> . Cette méthode est utilisée pour trouver des tendances dans les données, ou dans l'IA générative	Mixer des données annotées et non annotées	Le modèle apprend à partir de l'évaluation de la "qualité" de sa sortie. Il interagit avec l'environnement et il reçoit <u>récompenses ou pénalités</u> .
Régression linéaire, arbres de décision, réseaux neuronaux, etc.	Clustering, règles d'association, auto-encodeur...	<i>Label propagation</i>	Q-Learning

Apprendre par l'exemple

Apprentissage Supervisé

Données : (x, y)

x est une donnée d'entrée, y est une étiquette (par exemple, une photo avec l'étiquette "chat")

Objectif: Apprendre à associer l'entrée à la sortie, c'est-à-dire $x \rightarrow y$

Un exemple: pour classier Ceci est un chat



Un chat

Apprentissage Non Supervisé

Données: x ,
 x est une donnée, il n'y a pas d'étiquettes !

Objectif: Apprendre la structure sous-jacente des données.

Un exemple: Comparaison, regroupement



Ces deux choses se ressemblent

Apprentissage par Renforcement

Données: pas de données, seulement des paires état-action (s, a)

Objectif: Maximiser la récompense future sur plusieurs étapes temporelles.

Un exemple: récompense = joie



L'interaction avec le chat donne de la joie

(A) Processus d'entraînement par apprentissage supervisé

Annotation

La “**vérité terrain**” (*ground truth*) est partagée en données d'entraînement, d'évaluation et de test. Ces données sont annotées/labellisées/étiquetées.

L'annotation est la tâche au cours de laquelle un humain attribue une “étiquette/label” à une donnée.


Entraînement

En fonction des données et de la tâche qu'on doit résoudre, on choisit une approche et un **algorithme d'apprentissage**. Celui-ci apprend les données d'entraînement avec leur annotation et on obtient un modèle (entraîné).

Evaluation

Ce modèle est d'abord testé sur des données de test. Si les résultats ne sont pas satisfaisantes, on revient à l'étape d'entraînement pour modifier **les paramètres** de l'algorithme **ou les données** d'entraînement. Sinon le modèle est prêt pour entrer en production.

Comment annoter ?



roboflow.com

- Selon la nature des données
- Selon les modes d'annotation
- Outillage :
 - [LabelStudio](#)
 - [Roboflow](#)
 - [LabelImg](#)
 - [VGG Image Annotator](#)
 - [Prodigy](#)
 - [Callico](#) (Teklia)
 - ...

Théorie de l'apprentissage supervisé


Objectif : l'algorithme apprend à partir de données étiquetées pour prédire une sortie à partir d'une entrée. Une fois un modèle entraîné, il est possible de prédire la sortie pour des données jamais vues ("inférence" du modèle sur une donnée).

Entrées (features) : les informations connues (X)


Sortie : la réponse : valeur numérique ou quantitative (*régression*) / valeur catégorique ou qualitative (*classification*)

$$Y_n = f(X_n) + \varepsilon_n$$

Algorithme d'apprentissage supervisé = algorithme d'optimisation cherchant la fonction f qui minimise l'écart entre les prédictions du modèle et les sorties attendues (*perte*).




Classification / régression




$Y = \text{catégorie (classe)}$

$Y = \text{valeur}$




Données quantitatives ou qualitatives



Régression linéaire

Un modèle statistique qui cherche à approximer la relation entre une ou plusieurs variables indépendantes ($x_1, x_2, \dots$) et une variable dépendante y par une ligne droite (ou un hyperplan en plusieurs dimensions). Le modèle est souvent estimé par la “méthode des moindres carrés” mais il existe d’autres méthodes.

*Comment prédire l'efficacité énergétique d'une voiture
en fonction de sa masse ?*



Une seule variable en entrée : masse (x_1)

Sortie : y'


Biais du modèle : b (appris)

Poids de la variable : w_1 (appris)

$$y' = b + w_1 x_1$$

Régression linéaire : inférence (prédiction)

Le modèle peut désormais **prédire** sa sortie à partir d'une donnée d'entrée.




Prédiction du modèle pour
masse = 4.0 ?

$$\begin{aligned}y' &= 34 + (-4.6)(x_1) \\ &= 15,6\end{aligned}$$

Régression linéaire multivariable

Plusieurs variables indépendantes (prédicatives, explicatives) : $x_1, x_2, \dots$

Cas avec deux variables



efficacité énergétique



$$y' = b + w_1 x_1 + w_2 x_2 + \dots$$

masse

puissance

Linéaire ?

A. Il doit exister une relation linéaire entre la variable dépendante et la(les) variable(s) indépendante(s).



B. Linéaire signifie que le modèle est linéaire par rapport aux paramètres (coefficients), et non forcément par rapport aux variables elles-mêmes.


$$y = ax + b$$

$$y = ax^2 + b \ln(x) + c$$

...

Perte

La perte est une métrique numérique qui décrit le **degré d'inexactitude des prédictions** d'un modèle. La perte mesure la distance entre les prédictions du modèle et les libellés réels. L'objectif de l'entraînement d'un modèle est de minimiser la perte, en la réduisant à sa valeur la plus basse possible.




Mesure de la perte :

$$\sum |valeur\ réelle - valeur\ prédite|$$

Autres mesures : erreur absolue moyenne, erreur quadratique moyenne (MSE)...

ATELIER : perte





<https://developers.google.com/machine-learning/crash-course/linear-regression/parameters-exercise?hl=fr>

<https://tinyurl.com/3t4mphcy>

Régression logistique

Comment faire lorsque la sortie du modèle est binaire, décrivant la présence ou l'absence d'une caractéristique qualitative ?


*Comment prédire la solvabilité
d'un emprunteur bancaire ?*




Régression logistique

Un modèle statistique qui cherche à prédire la probabilité d'un résultat donné. Il tente d'expliquer au mieux une variable binaire (la présence ou l'absence d'une caractéristique donnée) à partir d'observations réelles. Il s'agit d'une régression linéaire pour le cas catégoriel.

La fonction **sigmoïde** transforme les valeurs réelles en une probabilité entre 0 et 1.




Fonction sigmoïde (en forme de S)



Variables explicatives X
Sortie : y' (probabilité entre 0 et 1)

$$P(y' = 1 | X)$$



Régression logistique

Un coefficient (poids w) positif signifie que les cotes logarithmiques du résultat augmentent à mesure que l'entrée (x) augmente. Cela correspond à une hausse de la probabilité. Un coefficient nul signifie que la variable n'a aucun effet sur le résultat.


$$z = b + w_1 x_1 + w_2 x_2 + \dots + w_N x_N \qquad y' = \frac{1}{1 + e^{-z}}$$

Les probabilités sont bornées entre 0 et 1, ce qui complique une modélisation linéaire directe. La fonction logit « débloque » ces bornes et permet d'utiliser des outils de régression linéaire.

$$z = \log\left(\frac{p(x)}{1 - p(x)}\right)$$

Classification


L'objectif n'est plus de générer une probabilité, mais une catégorie (iris bleu ou vert, vrai/faux, spam/non spam...). Pour effectuer cette conversion, il faut choisir une probabilité de seuil (**seuil de classification**). Le choix du seuil (lié aux données et au contexte) influe sur les résultats.




Linéaire ?

A. Il doit exister une relation linéaire entre la variable dépendante et la(les) variable(s) indépendante(s).

Linear



Non Linear





C. Les données doivent être linéairement séparables



B. Linéaire signifie que le modèle est linéaire par rapport aux paramètres (coefficients), et non forcément par rapport aux variables elles-mêmes.

$$y = ax + b$$

$$y = ax^2 + b \ln(x) + c$$






B. Evaluation des résultats



Les ensembles de données

- Ensemble de données étiquetées (« vérité terrain »)
- Données d'apprentissage / données de validation pour l'algorithme d'apprentissage
- Données de test : évaluation humaine des performances sur des données jamais vues par le modèle



FP (faux positif), FN (faux négatif), VP (vrai positif), VN (vrai négatif)

Ces notions sont utilisées en statistiques, tests médicaux et apprentissage automatique pour évaluer les résultats d'un test ou d'un modèle de classification. On part de :

- la réalité (positif ou négatif),
- du résultat du test ou du modèle (positif ou négatif).

On classe les effectifs des 4 populations dans un tableau.

RÉALITÉ

PRÉDICTION


	Vrai positif	Vrai négatif
Prévision positive	Vrai positif (VP): e-mail indésirable correctement classé comme tel. Il s'agit des messages de spam automatiquement envoyés dans le dossier de spam.	Faux positif (FP): e-mail non indésirable classé à tort comme spam. Il s'agit des e-mails légitimes qui se retrouvent dans le dossier de spam.
Prévision négative	Faux négatif (FN): e-mail de spam classé à tort comme non spam. Il s'agit d'e-mails indésirables qui ne sont pas détectés par le filtre antispam et qui se retrouvent dans la boîte de réception.	Vrai négatif (VN): e-mail non spam correctement classé comme tel. Il s'agit des e-mails légitimes qui sont envoyés directement dans la boîte de réception.

Matrice de confusion


Ce tableau est appelé matrice de confusion. Elle mesure la qualité d'un système de classification. Chaque ligne correspond à une classe réelle, chaque colonne correspond à une classe estimée (prédite). Permet de visualiser les erreurs du modèle. Matrice idéale : diagonale pleine, 0 ailleurs

Cas d'un détecteur de spams


	vrais positifs	vrais négatifs
prévisions positives	 TP=3	 FP=3
prévisions négatives	 FN=3	 TN=90



Cas des espèces d'iris



ATELIER : seuil de classification et matrice de confusion



Détecteur de spams : influence du seuil de classification


<https://developers.google.com/machine-learning/crash-course/classification/thresholding?hl=fr>

<https://tinyurl.com/bdxfwj fz>

Comment évaluer les performances ?

Métriques d'évaluation : taux de **rappel**, de **précision**, d'exactitude

Score F (ou F1) : moyenne harmonique de la précision et du rappel



métriques

Accuracy (exactitude)	$\frac{VP + VN}{Total}$	Taux de prédictions correctes
Rappel (recall, sensibilité)	$\frac{VP}{VP + FN}$	Taux de vrais positifs. À quel point le modèle reconnaît un cas positif quand il y en a un.
Précision	$\frac{VP}{VP + FP}$	Probabilité que le modèle ait raison quand il prédit un cas positif.
F1-score	$\frac{2 \times \text{précision} \times \text{rappel}}{\text{précision} + \text{rappel}}$	Pour mesurer l'équilibre entre précision et rappel.
Spécificité (specificity)	$\frac{VN}{VN + FP}$	Taux de vrais négatifs. À quel point le modèle reconnaît un cas négatif quand il y en a un.
Valeur prédictive négative (VPN)	$\frac{VN}{VN + FN}$	Probabilité que le modèle ait raison quand il prédit un cas négatif.

Rappel et précision : impact selon les cas d'usage




Tous les bons livres



Tous les bons livres
recommandés

Dans un système de recommandation de lecture, il faut que tous les livres recommandés par le système correspondent aux attentes du lecteur (précision). Mais on peut accepter que le système en oublie (rappel).

Rappel et précision : impact selon les cas d'usage




Cas du détecteur de spams

Rappel et précision : impact selon les cas d'usage

Métrique	Conseils
Précision	Utilisez-le comme indicateur approximatif de la progression/convergence de l'entraînement du modèle pour les ensembles de données équilibrés. Pour les performances du modèle, n'utilisez cette métrique qu'en combinaison avec d'autres métriques. À éviter pour les ensembles de données déséquilibrés. Envisagez d'utiliser une autre métrique.
Rappel (taux de vrais positifs)	À utiliser lorsque les faux négatifs sont plus coûteux que les faux positifs.
Taux de faux positifs	À utiliser lorsque les faux positifs sont plus coûteux que les faux négatifs.
Précision	À utiliser lorsque la précision des prédictions positives est très importante.

ATELIER : matrice de confusion (Scikit + JupyterLite)



Dataset "Iris": 4 valeurs continues (largeur et longueur pétale et sépale)

[[5.1 3.5 1.4 0.2]]

[4.9 3. 1.4 0.2]

[4.7 3.2 1.3 0.2]

[4.6 3.1 1.5 0.2]

[5. 3.6 1.4 0.2]

[5.4 3.9 1.7 0.4] ...

['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']

1 espèce d'iris (parmi 3)

```
[0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0]
```

00000000011111111111111111111111111111111111

111111111111111122222222222222222222

222222222222222222222222]


['setosa' 'versicolor' 'virginica']

150 lignes

https://scikit-learn.org/1.4/auto_examples/datasets/plot_iris_dataset.html

<https://tinyurl.com/3ff68ed9>

ATELIER : matrice de confusion (Scikit + JupyterLite)



Problème = classification
Entrées : 4 valeurs continues

Classifieur : SVM
Sortie : une espèce parmi trois
à prédire


https://scikit-learn.org/stable/auto_examples/model_selection/plot_confusion_matrix.html

<https://tinyurl.com/3yud9cw3>


ROC et AUC

Les métriques précédentes sont calculées à une seule valeur de seuil de classification. Si on souhaite évaluer la qualité d'un modèle pour tous les seuils possibles, il faut utiliser les courbes ROC et AUC. Bon pour les datasets équilibrés, où le nombre de positifs et négatifs est similaire.


Courbe ROC (*Receiver Operating Characteristic*) : Graphiquement, on la représente sous la forme d'une courbe qui donne le taux de vrais positifs (fraction des réellement positifs qui sont effectivement détectés comme positifs) en fonction du taux de faux positifs (fraction des réellement négatifs qui sont, à tort, détectés comme positifs).



Courbe parfaite




Courbe d'un modèle à 50% (aléatoire)




Courbe d'un modèle réel

ROC et AUC


L'aire sous la courbe ROC (AUC, *area under ROC*) représente la probabilité que le modèle, s'il reçoit un exemple positif et un exemple négatif choisis aléatoirement, classe l'exemple positif plus haut que l'exemple négatif.



AUC = 1




Courbe d'un modèle à 50% (aléatoire)



Courbe d'un modèle réel

ROC et AUC : interprétation

Les points d'une courbe ROC les plus proches de (0,1) représentent une plage des seuils les plus performants pour le modèle donné. Le seuil choisi dépend de la métrique la plus importante pour le cas d'usage considéré.




Point A : Si les faux positifs (fausses alarmes) sont très coûteux, il est judicieux de choisir un seuil qui donne un FPR plus faible.

Point C : Si les faux positifs sont peu coûteux et les faux négatifs (vrais positifs manqués) très coûteux, le seuil du point C, qui maximise le TPR, est préférable.

Point B : Si les coûts sont équivalents, le point B offre le meilleur équilibre.

Courbe précision/rappel

L'AUC et le ROC sont utiles pour comparer des modèles lorsque l'ensemble de données est à peu près équilibré entre les classes. Lorsque l'ensemble de données est déséquilibré, les courbes de précision-rappel (PRC) et la zone sous ces courbes offrent une meilleure visualisation comparative des performances du modèle. Les courbes de précision/rappel sont créées en traçant la précision sur l'axe Y et le rappel sur l'axe X, pour tous les seuils.



ATELIER : courbe ROC




Détecteur de spams

<https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=fr>

C. Apprentissage machine (suite)

Types de méthode d'apprentissage supervisé

- Machine à vecteurs de support (SVM)
- Réseau de neurones artificiels
- Méthode des k plus proches voisins
- Arbre de décision
- Classification naïve bayésienne
- Inférence grammaticale
- Espace de versions
- ...



Arbres de décision

Objectif : quels sont les attributs des données qui permettent d'expliquer (prédire) une variable ?


Exemple des iris :

- Attributs : largeur, longueur (pétales et sépales)
- Variable à expliquer (qualitative) : 3 espèces d'iris


Algorithme : principe de partitionnement récursif, qui créer des groupes d'individus aussi homogènes que possible par rapport à la variable que l'arbre cherche à prédire, à partir de seuil de valeur des attributs.

Avantage : lisible par un humain (explicable), rapide.

Dérivées + performantes : forêt d'arbres aléatoires (random forest) et amplification de gradient (gradient boosting)



ATELIER : arbre de décision (Scikit + JupyterLite)



La variable $x[2]$ (longueur pétale) permet de prédire la classe n° 1 (setosa). Cf. graphe de l'atelier "Matrice)

critère : $x[2] \leq 2.45$


https://scikit-learn.org/stable/auto_examples/tree/plot_iris_dtc.html

<https://tinyurl.com/fwme8f2p>


Le neurone formel

The Formal Neuron: 1943 [McCulloch and Pitts, 1943]

- Premier modèle mathématique et informatique du neurone biologique
- Associe des entrées et une sortie. Les entrées sont excitatrices ou inhibitrices
- Si la somme pondérée s des entrées excitatrices dépasse le seuil d'activation du neurone b , la sortie du neurone est 1 (activée)
- Fonction d'activation non linéaire (sortie non proportionnelle à l'entrée)





Dans la formulation d'origine de McCulloch et Pitts, la fonction d'activation est la [fonction de Heaviside](#) (fonction en *marche d'escalier*), et les entrées sont binaires (0/1, sorties d'autres neurones)



McCulloch et Pitts, 1943

Voir aussi ["La revanche des neurones
L'invention des machines inductives et la
controverse de l'intelligence artificielle"](#),
Dominique Cardon, Jean-Philippe Cointet
et Antoine Mazières, *Réseaux*, 2028


Neurone biologique ?



Analogie entre ce modèle computationnel de neurones formels et les neurones biologiques : « Si le neurone est suffisamment excité, il atteint un potentiel d'activation suffisant ».

Note : forte simplification du fonctionnement du système nerveux central. Par exemple, entrées = dendrites


Fonction d'activation




La fonction « échelle » affecte une valeur de sortie égale à 1 si la sortie est positive et une valeur 0 sinon

On peut voir le neurone formel comme effectuant une étape de **binarisation**, où le neurone est activé si la valeur de la combinaison des entrées et des poids est supérieure à un seuil - b (seuil d'activation)

D'autres fonctions sont possibles, permettant une prise de décision moins raide et une sortie à valeur réelle : sigmoïde, tangente, RELU...



Sigmoïde





RELU

Fonction d'activation : non linéarité


Intuitivement, une transformation non linéaire modifie la représentation spatiale des données. Une transformation linéaire permet de modifier les données (par ex. par $\times$), mais n'a pas d'influence sur leur représentation spatiale.

Les réseaux de neurones sont une famille d'architectures conçues pour trouver des modèles non linéaires dans les données. Lors de l'entraînement d'un réseau de neurones, le modèle apprend automatiquement les croisements de caractéristiques optimaux à effectuer sur les données d'entrée afin de minimiser les pertes.




Application : fonctions booléennes


- Tous les poids sont égaux (1)
- Entrées binaires
- Sortie binaire :
 $\hat{y} = f(s) = 1$ si $\text{somme}(x_i) \geq b$
 $= 0$ si $\text{somme}(x_i) < b$



fonction ET




fonction OU



fonction NON


- Si $x_1 = 0$, le neurone n'est pas inhibé et l'excitation est 0, qui est égale au seuil de 0. La sortie est 1.
- Si $x_1 = 1$, le neurone est inhibé, la sortie est de 0.

Frontières de décision



Fonction ET

2 entrées, frontière de décision (linéaire) = **ligne**



Fonction OU

3 entrées, frontière de décision (linéaire) = **plan**

Le Perceptron

Un cas particulier de neurone formel — un modèle concret avec un mécanisme d'apprentissage spécifique — monocouche — fonction d'activation = escalier (ou autres) — entrées continues / sortie binaire (classifieur binaire)


Apprentissage :

1. Initialiser poids et biais avec des valeurs aléatoires
2. Prendre un point de données
3. Calculer la sortie pour le point ; si elle est correcte, continuer en 2
4. Sinon mettre à jour les paramètres pour que la sortie soit correcte.
5. Aller en 2 sauf si un *epoch* a passé sans mise à jour des paramètres ou qu'une limite est dépassée (cas des données non séparables)

Frank Rosenblatt (1958),
Minsky and Papert (1969)



Le Perceptron




$$y = \begin{cases} 1 & \text{si } \sum_{i=1}^n w_i x_i \geq \theta \\ 0 & \text{sinon} \end{cases}$$

Fonction de Heaviside :

$$\forall z \in \mathbb{R}, H(z) = \begin{cases} 0 & \text{si } z < 0 \\ 1 & \text{si } z \geq 0. \end{cases}$$

$$y = H \left(\sum_{i=1}^n w_i x_i - \theta \right)$$

ATELIER : entraînement d'un Perceptron



Example correctly classified => no update

One epoch completed.

The classifier has not changed during this epoch:
the algorithm converged in 2 epochs.

Classifier parameters :

$w = [-7.31 , -0.55]$

$b = 1.46$


Problème = classification binaire

Entrées : 2 valeurs continues

Sortie : binaire

<https://mlweb.loria.fr/book/en/perceptron.html>

ATELIER : entraînement d'un Perceptron



Problème = classification

Paramètres :

- 2 entrées
- 0 couche cachée
- Activation = Linear


Données :

- Dataset linéairement séparable (gaussien)
- Bruit = 0



<https://playground.tensorflow.org>

Comment gérer la non-linéarité ?

Régression : frontières non linéaires



Classification multiclasse



"Non linéaire" signifie qu'il n'est pas possible de prédire selon de bonnes performances avec un modèle de la forme :

$$z = b + w_1x_1 + w_2x_2 + \dots + w_Nx_N$$


La "surface de décision" n'est pas une ligne/plan.

Idem s'il existe des interactions entre variables en entrée (par ex. âge et revenu). Les croisements de caractéristiques (et les transformations polynomiales, par ex. x^2) permettent aux modèles linéaires de gérer les non-linéarités et aussi d'encoder les interactions entre caractéristiques :

$$z = b + w_1x_1 + w_2x_2 + w_3x_1x_2$$

Avoir une connaissance du domaine permet de trouver une combinaison efficace de caractéristiques à croiser (ou de transformations polynomiales).

ATELIER : entraînement d'un Perceptron : croisement de caractéristiques



<https://playground.tensorflow.org>


Problème = classification

Paramètres :


- 2 entrées x_1 et x_2
- + 1 croisement $x_1 x_2$
- 0 couche cachée
- Activation = Linear

Données :

- Dataset non linéairement séparable (XOR)



ATELIER : entraînement d'un Perceptron : transformation polynomiale



Problème = classification

Paramètres :

- 2 entrées x_1^2 et x_2^2
- 0 couche cachée
- Activation = Linear

Données :

- Dataset Cercles

<https://playground.tensorflow.org>

Théorème d'approximation universelle


Théorème d'approximation universelle : un réseau à propagation avant d'une seule couche cachée contenant un nombre fini de neurones (i.e un perceptron multicouche) et des fonctions d'activation appropriées (non linéaires), peut approximer des fonctions continues sur des sous-ensembles compacts de $\mathbb{R}^n$.
George Cybenko (1989) et Kurt Hornik (1991)

Dit autrement :

Un réseau suffisamment large peut représenter n'importe quelle relation non linéaire entre les entrées et la sortie.

Le théorème ne garantit pas :

- que l'algorithme d'entraînement trouvera ces paramètres,
- ni que le réseau généralisera bien hors des données,
- ni que le nombre de neurones requis soit raisonnable.



[Voir aussi](#)

Théorème d'approximation universelle

- Il est possible d'utiliser des réseaux de neurones pour trouver et appliquer automatiquement des combinaisons de caractéristiques utiles pendant l'entraînement. Les réseaux de neurones apprennent implicitement ces croisements de caractéristiques.
- Une couche cachée apprend des combinaisons non linéaires de variables. Des couches profondes apprennent des interactions hiérarchiques de plus en plus complexes.
- Le TAU garantit que, théoriquement, ces interactions suffisent à approximer toute fonction.


Dit autrement :

Les croisements de caractéristiques sont une manière explicite de représenter des interactions, tandis que le théorème d'approximation universelle garantit que les réseaux neuronaux peuvent apprendre ces interactions implicitement, à condition d'être suffisamment larges et non linéaires.


[Voir aussi](#)

Retour sur la non-linéarité

- Nécessité d'ajouter des Perceptrons ou des couches de Perceptrons (réseau multicouche, MPL)
→ réseaux "profonds" (*deep*)
- Tous les neurones sont interconnectés.
- La fonction d'activation est non linéaire.
- Pour chaque neurone de sortie : $\hat{y}_k$ = probabilité d'être dans la classe k connaissant l'entrée x






ATELIER : Perceptron multicouche et activation linéaire






Fonction d'activation linéaire : la sortie est une combinaison linéaire des entrées, même avec plusieurs couches (suite de multiplications et d'additions)

<https://developers.google.com/machine-learning/crash-course/neural-networks/nodes-hidden-layers>

Frontières de décision non linéaires




Fonctions sigmoïdes (S)



La sortie n'est pas en relation linéaire avec l'entrée.

[Voir aussi](#)

ATELIER : Perceptron multicouche et activation non linéaire





Fonction d'activation linéaire sigmoïde : la sortie est non linéaire

La sortie de chaque nœud est désormais une transformation sigmoïde de la combinaison linéaire des nœuds de la couche précédente.

$$\begin{aligned} &= \text{Sigmoid}(w_{11} x_1 + w_{21} x_2 + w_{31} x_3 + w_{41} x_4 + b) \\ &= \text{Sigmoid}(0.09 * 0.49 + 0.40 * 0.60 + -0.04 * 0.25 \\ &\quad + 0.17 * 0.25 + 0.78) \\ &= \text{Sigmoid}(0.04 + 0.24 + -0.01 + 0.04 + 0.78) \\ &= \text{Sigmoid}(1.09) \\ &= 0.75 \end{aligned}$$

<https://developers.google.com/machine-learning/crash-course/neural-networks/nodes-hidden-layers>


ATELIER : entraînement d'un Perceptron multicouche




Paramètres :

- Données concentriques
- **Fonction d'activation RELU ou sigmoïde**
- 2 entrées
- 1 couche cachée, 2 Perceptrons

- Fonction sigmoïde
- 1 couche caché, 3 Perceptrons
- Chaque Perceptron produit une frontière de décision linéaire




ATELIER : entraînement d'un Perceptron multicouche




Paramètres :

- Données spirales
- Fonction RELU
- 2 entrées
- 1 couche cachée de 8 Perceptrons



- 4 couches de 4 Perceptrons
- 2 couches cachées de 8 Perceptrons

ATELIER : entraînement d'un Perceptron multicouche avec Keras



```
# iris-neural-network.ipynb
Fichier Modifier Affichage Insérer Exécution Outils Aide

Commandes + Code + Texte Tout exécuter Reconnecter

Importing the data set

# Reference links:
# Adapted from: https://github.com/emerging-technologies/keras-iris
# Data set pulled from: https://gist.github.com/curran/a08a1080b88344b0c8a7

# imports and preliminaries
import csv
import numpy as np
import keras as kr
import requests
from io import StringIO



url = "https://gist.githubusercontent.com/netj/8836201/raw/6f9306ad21398ea43cba4f7d537619d0e07d5ae3/iris.csv"

# Load the Iris dataset.
response = requests.get(url)
response.raise_for_status() # Raise an error for bad responses

# Read the CSV content
csv_content = StringIO(response.text)
csv_reader = csv.reader(csv_content)

iris = list(csv_reader)[1:]
print(iris)

... [['5.1', '3.5', '1.4', '0.2', 'Setosa'], ['4.9', '3', '1.4', '0.2', 'Setosa'], ['4.7', '3.2', '1.3', '0.2', 'Setosa'], ['4.6',
```



https://github.com/altomator/Formation_IA/tree/main/perceptron

<https://tinyurl.com/3ztyx55f>

(B) Processus de l'apprentissage non supervisé

Annotation

Aucune

Entraînement

L'apprentissage non supervisé utilise des algorithmes d'**auto-apprentissage**, c'est-à-dire qu'il apprend sans étiquettes ni entraînement préalable. Le modèle reçoit des données brutes et non étiquetées, et doit inférer ses propres règles et structurer les informations en fonction des similitudes, des différences et des modèles, sans instructions explicites.

Evaluation

L'évaluation est une analyse humaine des résultats (interprétation). Il n'existe pas de référence à laquelle comparer les résultats.


Clusterisation (partitionnement de données)

Partager les données en sous-ensembles (*clusters*) partageant des caractéristiques communes, qui correspondent à des critères de proximité (similarité).

Plusieurs approches :

- méthodes basées centroïdes telles que les algorithmes des k-moyennes (KMeans),
- méthodes de regroupement hiérarchique,
- méthodes basés sur la densité (DBSCAN, OPTICS),
- méthodes connexionnistes (cartes auto adaptatives)
- ...

Difficultés : nombre optimal de clusters, interprétation des clusters



[Voir aussi](#)

ATELIER : K-Means (k-moyennes)




<https://clustering-visualizer.web.app/>

Algorithme K-Means :

- minimiser la distance (euclidienne) entre les points de données et le centre de cluster,
- par itération,
- algorithme simple mais sensible aux conditions initiales et aux données aberrantes.

Auto-encodeur (autosupervision)




L'objectif de l'auto-encodeur est de reconstruire ses entrées : prédire une valeur cible X' la plus proche possible des entrées X (plutôt que de prédire une valeur cible Y). Il n'est pas supervisé par la connaissance de Y . Il s'agit en fait d'un d'apprentissage *autosupervisé*. Pas besoin de données annotées !

La forme la plus simple d'un auto-encodeur est un réseau de neurones qui se propage vers l'avant, semblable au Perceptron multicouches.


L'auto-encodeur a une couche d'entrée X , une couche de sortie X' ainsi qu'une ou plusieurs couches cachées les reliant. X et X' ont le même nombre de dimensions. Note : pour certains cas d'usage, le module de décodage n'est pas utilisé.

Le code z (aussi appelé variables latentes ou représentation latente ou *embedding*) est la couche cachée la plus interne. Elle représente X mais dans un espace avec moins de dimensions, qui capturent les caractéristiques les plus importantes de l'entrée



2 modules : encodeur / décodeur

Auto-encodeur : usages



Réduction de dimensionnalité : La réduction de la dimensionnalité des données complexes permet d'extraire des caractéristiques pertinentes pour d'autres tâches, et d'augmenter la vitesse et l'efficacité de calcul.
La dimension du code z spécifie le facteur de réduction.

Extraction de caractéristiques : le code z (*embeddings*) permet classification, recherche de similarité, etc.


Compression de données : les auto-encodeurs apprennent naturellement une représentation compressée de l'entrée.

Débruitage : les auto-encodeurs peuvent supprimer les artefacts ou les corruptions qui ne correspondent pas à la représentation de l'espace latent apprise par le réseau.

Détection d'anomalies : Les anomalies sont détectées en identifiant les points de données qui ont une erreur de reconstruction élevée lorsqu'ils sont traités par l'auto-encodeur (points jamais vus pendant l'entraînement).

Prétraitement avant un modèle supervisé.

ATELIER : Auto-encodeur




- [Article](#)
- [Github](#)

VAE = *Variational Autoencoders* (2013).
Un VAE est un type particulier d'auto-encodeur en apprentissage automatique, utilisé principalement pour la génération de données et la modélisation probabiliste. Il combine des concepts d'auto-encodeurs classiques et de modèles probabilistes bayésiens.

<https://xnought.github.io/vq-vae-explainer/>

Voir aussi CNRS-Fidle : [Autoencodeurs](#)

ATELIER : Auto-encodeur



https://magenta.tensorflow.org/assets/sketch_rnn_demo/index.html



D. Un champ de l'IA : comprendre les images



L'application de l'apprentissage machine aux images

“Vision assistée par ordinateur ou *computer vision*”


Champ de l'IA qui vise à reconnaître et extraire des informations depuis des images fixes ou animées.

Champs d'application : conduite autonome, reconnaissance faciale, robotique, documentation et média, etc.



Source : BnF

Classification et détection




Color	Predicted Class
■	Nameplate
■	Headline
■	Photograph
■	Illustration

Classification d'image : identifier la nature de l'image selon des catégories prédéfinies


Détection d'objet : identifier les objets présents dans une image

Types de classification


Binaire




Multiclasse





Multilabel



Multiclasse : un contre tous




N classificateurs binaires distincts, 1 classificateur pour chaque résultat possible



1 classificateur = 1 réseau de neurones profond, dans lequel chaque nœud de sortie représente une classe. Probabilité de "pomme" et "pas pomme" est calculée sans tenir compte de la probabilité des autres options de fruits : "orange", "poire" ou "raisin".

Multiclasse : un contre un (softmax)


Ici, nous voulons prédire les probabilités pour chaque fruit les uns par rapport aux autres ("pomme" par rapport à "orange" et "poire" et "raisin"). Ce type de classification à classes multiples est appelé *classification un contre un*.



1 réseau de neurones profond, dans lequel chaque nœud de sortie représente une classe. La couche de sortie attribue des probabilités à chaque classe d'un problème à classes multiples de sorte que la somme de toutes les probabilités est égale à 1,0.

La donnée d'entrée est une image...

Les **réseaux neuronaux convolutifs** (CNN) « simulent » le cortex visuel animal (chevauchement des neurones lors du pavage du champ visuel). Le réseau produit des descripteurs de plus en plus « abstraits ». Le classifieur final produit des catégories (“classes”).




Convolution ?

Convolution : appliquer un filtre sur tous les pixels de l'image, tuile par tuile, avec chevauchement entre tuiles.

ici, le filtre 101... appliqué sur une image noir et blanc (0/1 pour chaque pixel), produit 4 pour la tuile en haut à gauche.




En pratique, chaque pavé du champ visuel est traité par un Perceptron monocouche dont les poids sont ceux du filtre à appliquer

Un « noyau de convolution » est l'application d'un filtre qui extrait une caractéristique de l'image. Pour analyser plusieurs caractéristiques, on va empiler des strates de noyaux de convolution indépendants, chaque strate analysant une caractéristique de l'image.



Convolution, filtre 3x3

une image =
matrice de pixels



Input image

Filter

Feature map

Application d'un filtre et calcul du produit de convolution

Convolution et filtres

1 $\times 1$	1 $\times 0$	1 $\times 1$	0	0
0 $\times 0$	1 $\times 1$	1 $\times 0$	1	0
0 $\times 1$	0 $\times 0$	1 $\times 1$	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved
Feature


Application de la convolution sur l'image et génération d'une carte de caractéristiques : plus la valeur est élevée, plus cette portion de l'image ressemble au filtre !

- *forte réduction* du nombre de neurones connectés (analyse par tuiles de taille réduite)
- *poids partagés* : les paramètres de filtrage d'un neurone (pour un champ récepteur donné) sont identiques pour tous les autres neurones d'un même noyau de convolution
- *suppression* du bruit
- *invariance* à la position dans l'image des caractéristiques

Exemple de filtres

Operation	Kernel	Image result
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	


Exemple d'application d'un filtre



Convolution, filtre 3x3

0	0	0	0	0	30	0
0	0	0	0	30	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	0	0	0	0

Pixel representation of filter



Visualization of a curve detector filter

Filtre de détection de courbes penchées vers la droite

Exemple d'application d'un filtre



Visualization of the receptive field

0	0	0	0	0	0	30
0	0	0	0	50	50	50
0	0	0	20	50	0	0
0	0	0	50	50	0	0
0	0	0	50	50	0	0
0	0	0	50	50	0	0
0	0	0	50	50	0	0

Pixel representation of the receptive field

*


0	0	0	0	0	30	0
0	0	0	0	30	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	0	0	0	0

Pixel representation of filter



Multiplication and Summation = $(50 \times 30) + (50 \times 30) + (50 \times 30) + (20 \times 30) + (50 \times 30) = 6600$ (A large number!)

Application à une portion d'image : détection de la courbe



Visualization of the filter on the image

0	0	0	0	0	0	0
0	40	0	0	0	0	0
40	0	40	0	0	0	0
40	20	0	0	0	0	0
0	50	0	0	0	0	0
0	0	50	0	0	0	0
25	25	0	50	0	0	0

Pixel representation of receptive field

*


0	0	0	0	0	30	0
0	0	0	0	30	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	30	0	0	0
0	0	0	0	0	0	0

Pixel representation of filter

Multiplication and Summation = 0

Mais qui choisit les filtres ?


Avant les approches neuronales, il fallait choisir des filtres adaptés aux données (au corpus d'images à traiter, aux tâches d'analyse à mener). La phase d'apprentissage permet au réseau **d'autoconstruire** les filtres adaptés.





Entrée de l'image dans le réseau

Avant d'être injectée dans le réseau, une image subit plusieurs étapes de préparation :

- **Redimensionnement** : Les images doivent être redimensionnées à une taille fixe, par exemple 224×224 pixels pour des architectures comme ResNet ou VGG. Cela permet d'avoir des entrées cohérentes pour le réseau et des temps de calcul contenus.
- **Normalisation** : Les valeurs de pixels (souvent comprises entre 0 et 255 pour une image RGB) sont mises à l'échelle, généralement entre 0 et 1 ou centrées autour de zéro.
- **Conversion en tenseur** : L'image devient un tenseur 3D : (hauteur, largeur, canaux de couleur). Pour une image RGB 224×224 : (224, 224, 3).





Terminologie




Tenseur de représentation
d'une image couleurs (RVB)

- **Scalaire** : un nombre :
24
- **Vecteur** : plusieurs scalaires du même type de données :
(24, 33, 12)
- **Tuple** : scalaires de différents types de donnée :
("Jean", 27, 75002)
- **Matrice** : grille bidimensionnelle de scalaires, dans laquelle chaque ligne ou colonne est un vecteur :
([24, 33, 27]
[12, 8, 10]
[20, 12, 18])
- **Tenseur** : tableau de tableaux de nombres

Réseaux neuronaux convolutifs : architecture



ATELIER : visualisation 3D des couches




Modèles :

- LeNet
- Yolo


<https://tensor space.org/html/playground/inceptionv3.html>

CNN : extraction de “caractéristiques”


- Première couche : extraction de caractéristiques élémentaires (contours, aplats...)
- Les couches supérieures agrègent ces caractéristiques pour détecter des formes plus complexes




Visualizations of Layer 1 and 2. Each layer illustrates 2 pictures, one which shows the filters themselves and one that shows what part of the image are most strongly activated by the given filter. For example, in the space labeled Layer 2, we have representations of the 16 different filters (on the left)



Layer 3



Layer 4



Layer 5


Visualizations of Layers 3, 4, and 5

ATELIER : réseaux de neurones convolutifs



<https://poloclub.github.io/cnn-explainer/>

ATELIER : classification d'espèces d'iris avec Kaggle



Dataset : Iris

<https://www.kaggle.com/datasets/jeffheaton/iris-computer-vision/code>

Modèle CNN : MobileNetV2 (Google, 2024)

	precision	recall	f1-score
0	0.89	0.53	0.67
1	0.64	0.86	0.73
2	0.29	0.15	0.20
accuracy			0.63
macro avg	0.60	0.51	0.53
weighted avg	0.63	0.63	0.61

<https://www.kaggle.com/code/jpmoreux/iris-tf-cnn/>

<https://tinyurl.com/5n7bmv36>



E. Comprendre le langage




L'IA appliquée au langage

Le traitement automatique du langage naturel (TLN, TAL ou NLP) est un sous-domaine de l'IA qui joue un rôle essentiel dans l'amélioration des capacités des systèmes d'IA en les rendant plus aptes à **interagir de manière naturelle et efficace avec les humains**.

Le TAL implique le développement d'algorithmes, de modèles et de systèmes permettant **d'analyser, de comprendre et d'extraire des informations significatives à partir de données textuelles représentant le langage humain**.

L'IA générative a bouleversé les approches techniques antérieures (LLM, agent conversationnel)



Approches du TAL

Le TAL s'est appuyé sur plusieurs approches :

- **Approche linguistique** : Elle consiste à établir a priori des règles en étudiant le langage dans ses différentes dimensions (lexicale, grammaticale, syntaxique). Cette approche repose sur l'expertise humaine et la formalisation des connaissances linguistiques.
- **Approche statistique** : Elle exploite de grands corpus textuels pour analyser des patterns et extraire automatiquement des règles ou modèles grâce à des techniques d'apprentissage automatique. L'efficacité de cette approche dépend de la taille et de la qualité des données disponibles.
- **Hybride** : Elle combine les méthodes linguistiques et statistiques afin de tirer parti des forces de chaque approche, en utilisant à la fois des règles définies par l'humain et des modèles appris à partir des données.

TAL : cas d'usage

Analyse et compréhension du texte

- Recherche d'information (moteur de recherche)
- Analyse d'opinion/sentiments
- Extraction d'informations (dont la reconnaissance d'entités nommées)
- Classification de texte, détection de thèmes

Interaction homme-machine

- Agent conversationnel
- Reconnaissance vocale
- Commande vocale


Génération de texte

- Rédaction automatique
- Résumé automatique
- Correction et amélioration du texte
- Réponses automatiques

REN, NER

La reconnaissance des entités nommées (NER, *named entities recognition*) est un exemple d'application du TAL où une phrase ou une portion de texte est analysée pour en identifier des “entités” :

- personne,
- organisation,
- lieu,
- oeuvre,
- quantité, valeur monétaire, etc.



La plupart des systèmes d'étiquetages utilisent des **grammaires formelles** associées à des modèles statistiques, éventuellement complétées par des bases de données d'entités. Aujourd'hui, les modèles statistiques peuvent être des LLM.

ATELIER : extraction d'entités nommées

The screenshot displays the TextRazor web application interface. At the top, the TextRazor logo is on the left, and navigation links for Demo, Technology, Documentation, Pricing, Login, and a Sign up button are on the right. Below the header, there is an 'Edit Text' button and a status bar indicating 'Language: eng' and 'Processed in: 0.4679 seconds'.

The main content area shows two text samples with their respective analysis results. The first sample is a sentence about Barclays, and the second is about Manchester City. For each sample, a list of categories is provided on the right side of the interface.

Text Sample 1: Barclays misled shareholders and the public about one of the biggest investments in the bank's history, a BBC Panorama investigation has found.

Categories for Sample 1:

- 0.76 economy, business and finance>business information>business governance>shareholder activity
- 0.71 economy, business and finance>economy
- 0.62 crime, law and justice>crime
- 0.54 economy, business and finance>economy>macro economics>investments

Text Sample 2: The bank announced in 2008 that Manchester City owner Sheikh Mansour had agreed to invest more than £3bn.

Categories for Sample 2:

- 0.76 economy, business and finance>business information>business governance>shareholder activity
- 0.71 economy, business and finance>economy
- 0.62 crime, law and justice>crime
- 0.54 economy, business and finance>economy>macro economics>investments

<https://www.textrazor.com/demo>

REN, NER

Contrairement à une simple classification de mots, le REN est un **problème séquentiel** : la décision pour un mot dépend souvent du contexte, c'est-à-dire des mots voisins (avant, après) et des entités précédemment identifiées.

Approches basées sur des règles

- Expressions régulières
- Liste d'entités (gazetteers)
- Règles contextuelles

Approches statistiques :

- Modèles de Markov cachés (*HMM, Hidden Markov Models*)
- CRF (*Conditional Random Fields*), champs aléatoires conditionnels

Approches connexionnistes

- Réseaux de neurones récurrents (RNN) :
LSTM (Long Short-Term Memory) / BiLSTM (Bidirectional LSTM)
- Embeddings de mots contextualisés
 - ELMo :
 - BERT, RoBERTa, XLM-R
- Transformers spécialisés pour NER
- LLM avec apprentissage zero ou few-shot

Séquentialité

- Le langage a une forme séquentielle (suite linéaire d'unités textuelles). Dans le langage écrit, de gauche à droite et de haut en bas (dans la majorité des langues occidentales). Dans le langage oral, c'est le flux temporel des sons et des mots.
- Cette organisation est essentielle pour que le message soit intelligible et structuré.
- Les textes présentent des dépendances (locales ou à longue distance) :

*Le **chat dort** sur le canapé.*

***Alice** aime les mirabelles ; **elle** en mange très souvent.*

***Les décisions** de ma cheffe de service **sont** efficaces.*

ATELIER : CRF (Conditional Random Fields) pour le NER

Les CRF sont des modèles probabilistes discriminatifs qui permettent de prédire des séquences d'étiquettes en combinant des informations contextuelles riches et des contraintes sur les transitions, offrant ainsi une solution robuste pour identifier correctement les entités nommées dans un texte.

Chaque mot du texte est un **nœud** dans une séquence. Chaque mot reçoit une **étiquette**. Par exemple, selon le schéma **BIO** :

- B-PER : début d'une entité personne
- I-PER : continuation d'une personne
- O : mot en dehors d'une entité

```
<B-PER>Henri Martin</B-PER> a acheté <B-NUM  
TYPE="QUANTITY">300</B-NUM> actions de la société  
<B-ORG TYPE="ORGANIZATION">AMD</ B-ORG> en <B-NUM  
TYPE="DATE">2006</ B-NUM>.
```

Token	Tag
Henri	B-PER
Martin	I-PER
a	O
acheté	O
300	B-NUM
actions	O ...

Fonctions (d'état, de transition) de caractéristiques (*features*)

Type	Exemple
Lexical	Le mot est "Paris"
Morphologique	Le mot commence par une majuscule, suffixe "-ville"
Contextuel	Le mot précédent ou suivant est un titre ("Dr", "M.")
Gazetteers	Le mot figure dans une liste d'entités connues

Chaque fonction attribue 1 si la condition est vraie et 0 sinon.

ATELIER : CRF (Conditional Random Fields)



Deux approches :


- Random Forests (mots)
- CRF (mots + contexte)

<https://www.kaggle.com/code/jpmoreux/ner-using-crf/>

<https://tinyurl.com/2s3m7hsf>



Réseaux récurrents : modéliser les dépendances temporelles

Un RNN (*recurrent neural network*) est similaire à un réseau de neurones classique, dans lequel le flux des activations se dirige dans un sens unique, depuis la couche d'entrée vers la couche de sortie (propagation avant). Son architecture est composée d'une couche d'entrée, de couches cachées et d'une couche de sortie. En revanche, le RNN se distingue par la capacité de certaines connexions à **revenir en arrière** dans le réseau. La sortie d'un neurone récurrent étant une fonction de toutes les entrées des étapes précédentes, *on considère que ce neurone possède une forme de mémoire.*




- Traitement de séquences temporelles : données financières, météorologiques ou des capteurs IoT,
- Traitement du langage naturel : traduction automatique, génération de texte, reconnaissance vocale.
- Reconnaissance vocale et musicale : modéliser des sons ou des mélodies,
- Analyse de séries biologiques : séquences ADN, protéines, ou signaux biomédicaux dépendant de l'ordre des éléments.
- Génération de séquences : création de texte, musique, mouvements, etc.

Réseaux récurrents : modéliser les dépendances temporelles



ATELIER RNN : un RNN sait-il additionner ?



Le réseau apprend à additionner par l'exemple, grâce aux dépendances locales séquentielles :


$$12 + 5 = 17$$

$$8 + 12 = 20$$

...

Paramètres du réseau :

- couches cachées (3-4 max)
- nombre de neurones par couche



<https://storage.googleapis.com/tfjs-examples/addition-rnn/dist/index.html>

<https://tinyurl.com/55xahw44>

LSTM (Long Short-Term Memory)


Les RNN sont conçus pour traiter des séquences (texte, séries temporelles, audio, etc.) en réutilisant l'état caché de la couche précédente pour calculer la prochaine étape temporelle. Cependant, ils souffrent de deux problèmes majeurs :

- Lors de l'entraînement sur de longues séquences, le **gradient** transmis rétroactivement peut devenir très petit, empêchant l'apprentissage de dépendances à long terme.
- Dans certains cas, le gradient peut devenir très grand, rendant l'entraînement instable.


Cela limite les RNN classiques à capturer efficacement des relations à court terme dans les données séquentielles. Les LSTM sont une variante de RNN conçue pour résoudre ce problème. Leur innovation est l'unité de mémoire (*cell state*) et les portes :

- **Porte d'entrée** : contrôle quelles nouvelles informations sont ajoutées à la mémoire.
- **Porte d'oubli** : décide quelles informations anciennes doivent être conservées ou oubliées.
- **Porte de sortie** : détermine quelles informations de la mémoire sont utilisées pour produire la sortie à l'instant t .


LSTM



Cellule RNN Vanilla



LSTM (Long Short Term Memory)



$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

L'état de la cellule de mémoire est composé par les sorties de la porte d'oubli (nourrie par l'information antérieure) et de la porte d'entrée (information de la donnée courante).

ATELIER LSTM

TensorFlow.js Text Generation:

Train a LSTM (Long Short Term Memory) model to generate text

DESCRIPTION

This example allows you to train a model to generate text in the style of some existing source text. The model is designed to predict the next character in a text given some preceding string of characters. Doing this repeatedly builds up a text, character by character.

STATUS

Model training: 22.6% complete... (1067 examples)

SOURCE DATA

Nietzsche

Commeant, le ballon, détesté de tous les objets, tels que
munition, armes, troupes, etc., était relégué dans les couches
supérieures de l'atmosphère, à une hauteur de quatre mille cinq
cents pieds. Les passagers, après avoir reconnu que la mer était
sous la nacelle, trouvant les dangers moins redoutables en haut
qu'en bas, n'avaient pas hésité à jeter par-dessus le bord les
objets dont ils étaient les plus avides, et ils cherchaient à ne plus rien
perdre de ce fléau de cette aune de leur appareil, qui les
soutenait au-dessus de l'abîme.

MODEL LOADING/CREATION

Model saved in IndexedDB: Saved @ 2025-01-11T17:21:41.213Z

LSTM layer size(s) (in g.


128 or 100 sq):

128

MODEL TRAINING

It can take a while to generate an effective model. Try increasing the number of epochs to improve the results, we have found that
about 80-100 epochs are needed to start generating reasonable text.

Number of Epochs:
Examples per epoch:
Batch size:
Validation split:
Learning rate:



<https://storage.googleapis.com/tfjs-examples/lstm-text-generation/dist/index.html>

<https://tinyurl.com/5fws78tb>

F. Modèles de langue

Les fondements des modèles de langue

- (a) **Calculer des représentations numériques** des entités linguistiques et de leurs propriétés (*embeddings*) afin de pouvoir calculer sur ces représentations.
- (b) **Utiliser ces représentations dans des modèles probabilistes** évaluant des décisions discrètes (classer un mail dans une parmi deux classes possibles ; prédire le mot suivant d'une phrase)
- (c) **Apprendre les paramètres de ces modèles** en exploitant des données annotées (des courriels corrects et incorrects) ou non annotées (des corpus textuels).


Attention : les modèles de langue ne sont pas des modèles de connaissance !

Plongement (*embeddings*)

Dans le traitement du langage naturel, le **word embedding** (plongement lexical) est un ensemble de techniques d'apprentissages permettant de représenter un mot (ou un *token*, une phrase, un document) sous une forme numérique adaptée. En représentant mathématiquement les tokens sous forme de tableaux de nombres réels (des **vecteurs**), on peut coder à la fois leur sens mais également les similitudes sémantiques qui existent entre eux.


Des mots sémantiquement similaires seront représentés par des vecteurs proches les uns des autres dans un espace vectoriel. Elle permet de manipuler mathématiquement les vecteurs, de les comparer, etc.

Voir aussi cette [ressource](#)



Représenter numériquement le texte ?

Approche 1 : Sac de mots (*bag of words*)



1. Décomposer en mots (token)
2. → Vocabulaire du modèle
3. Encoder les chaînes de caractère par rapport au vocabulaire constitué

Représenter numériquement le texte ?

Approche 2 : Plongements

	être vivant	chose	verbe	pluriel
Xavier	0,9	-0,2	-0,5	-0,6
oeufs	-0,9	0,8	-0,8	0,9
tartes	-0,9	0,7	-0,7	0,9
pommes	-0,9	0,8	-0,8	0,9
déteste	-0,8	0,5	0,9	-0,4


mots

plongements



4 vers 2

réduction
de dimensionalité



visualisation

Plongement de mots : calculer sur les vecteurs

king - man + woman $\approx$ queen



Dimensions et caractéristiques

Les « dimensions » des données ne se réfèrent pas aux dimensions de l'espace physique. Dans l'espace vectoriel, chaque dimension correspond à une **caractéristique individuelle des données**.

La détermination des caractéristiques pertinentes pour certaines modalités, comme les significations sémantiques et les relations contextuelles dans le langage, est subjective. Mais les caractéristiques spécifiques représentées par les dimensions des plongements vectoriels peuvent être définies soit manuellement, par une **ingénierie des caractéristiques** (*features*), soit par l'**apprentissage profond** : elles sont déterminées implicitement lors de l'entraînement d'un modèle.


Les plongements vectoriels efficaces pour des données à haute dimensionnalité impliquent une **réduction de la dimensionnalité** : la compression des données dans un espace à dimensions inférieures, en éliminant les informations non pertinentes ou redondantes.

Plongement : pas que pour le texte

Intuitivement, plus des points de données du monde réel sont similaires, plus leurs plongements vectoriels respectifs devraient l'être. Les caractéristiques ou qualités partagées par les points de données se reflètent dans leurs plongements, tandis que des points de données dissemblables auront des plongements vectoriels différents.

En conséquence, les plongements vectoriels peuvent être utilisés comme entrées dans des modèles exécutant des tâches utiles dans le monde réel, y compris pour représenter des points de données de différents types. Le plongement assure une forme d'**interopérabilité**, agissant comme un langage commun entre formats de données, en les représentant dans le même espace de plongement vectoriel. Par exemple, les assistants vocaux « traduisent » les entrées audio de l'utilisateur en plongements vectoriels, qui sont ensuite utilisés pour le traitement automatique du langage naturel de ces entrées.


Plongement : pas que pour le texte




Comparer des plongements ?

Plusieurs **mesures mathématiques** peuvent être utilisées pour déduire la similarité ou la proximité relative des plongements vectoriels. Le choix de la meilleure mesure dépend de la nature des données et de l'objectif des comparaisons : distance euclidienne, cosinus, produit scalaire...


similaire



sans relation



opposé



Plongement de mots : word2vec (Google, 2003)

- *Objectif* : transformer les textes en données numériques manipulables
- Transformer les mots en vecteurs numériques de façon à ce que des mots ayant un sens similaire soient proches dans l'espace vectoriel ($\neq$ *bag of words*)
- Dans un espace vectoriel dense et continu, où la proximité reflète la similarité sémantique. Hypothèse de distribution (*distributional hypothesis*) : « Les mots qui apparaissent dans des contextes similaires ont des significations similaires. »

word2vec ne gère pas polysémie (banque), morphologie (marche, marcher), les relations de sens non locales (relations sémantiques et syntaxiques de cooccurrences).

Comment entraîner word2vec ?


Algorithme d'apprentissage non supervisé avec un Perceptron à une couche cachée.

Architecture CBOW (*Continuous Bag of Words*) : le modèle est nourri par le contexte, et apprend à prédire le mot cible.


Texte : le chat mange la souris

Exemples :


Contexte	Cible
[le, mange]	chat
[chat, la]	mange
[mange, souris]	la



ATELIER : plongement de mots avec word2vec



<https://www.cs.cmu.edu/~dst/WordEmbeddingDemo/>



<https://projector.tensorflow.org/>


Plongement de mots : quels modèles ?

- Pour de nombreux cas d'usage, les modèles préentraînés fournissent des plongements utilisables comme entrées dans des modèles personnalisés. Ces modèles open source sont entraînés sur des ensembles de données très vastes pour apprendre des représentations utiles à de nombreuses tâches aval.
Word2Vec, GloVe, FastText, ELMo, BERT, RoBERTa, DistilBERT, ALBERT
- Certains cas impliquant des concepts complexes ou de nouvelles classes de données peuvent donner lieu à un ajustement personnalisé de modèles préentraînés ou de la création de modèles de plongement entièrement sur mesure (sciences, juridique, médical)
BioBERT, SciBERT
- **Modèles contemporains** : EmbeddingGemma, Qwen-Embedding...

ATELIER : clusterisation de textes

Problème : partitionner un ensemble de monographies en thématiques, à partir de leur notice catalogue

Données : métadonnées extraites des notices (titre, auteur, indexation sujet Rameau)



1. Vectorisation des textes (*sentence embeddings* avec all-MiniLM-L6-v2)
2. Clusterisation avec K-Means (Scikit-learn)
3. Visualisation 2D (UMAP)

<https://www.codeandcortex.fr/analyse-textuelle-kmeans/>

Github : <https://tinyurl.com/b7fd6vk9>

Unités lexicales (*token*)

En pratique, le **vocabulaire** d'une langue est potentiellement immense (emprunts, sigles, nombres, etc.). Un meilleur compromis (de calcul) est réalisé en abandonnant la notion de mot et en segmentant les textes en unités sous-lexicales, par des procédés qui sont eux-mêmes optimisés sur corpus pour prendre en compte les fréquences d'occurrence. Les mots fréquents sont ainsi préservés dans leur intégrité, tandis que les mots les plus rares sont divisés en sous-mots, le cas échéant réduits à des suites de symboles élémentaires.

Un **token** (jeton en français) est donc l'unité de base utilisée par les modèles de langage pour modéliser un texte. Il peut être une ponctuation, un mot ou une sous-unité plus petite comme un morphème. Chaque token est repéré par un identifiant unique propre à chaque modèle. L'ensemble des tokens constitue le *vocabulaire* d'un LMM.

Llama 3 : 250 000 tokens

Deepseek R1 : 128 000 tokens

GPT 3 : 50 000 tokens

*Equilibre entre la taille du vocabulaire
et les performances du modèle*

ATELIER : *tokenizer*

OpenAI Platform Docs API reference

Tokenizer

Learn about language model tokenization

OpenAI's large language models process text using **tokens**, which are common sequences of characters found in a set of text. The models learn to understand the statistical relationships between these tokens, and excel at producing the next token in a sequence of tokens. [Learn more.](#)

You can use the tool below to understand how a piece of text might be tokenized by a language model, and the total count of tokens in that piece of text.

GPT-4o & GPT-4o mini GPT-3.5 & GPT-4 GPT-3 (Legacy)

Un token (jeton en français) est l'unité de base utilisée par les modèles de langage pour modéliser un texte. Il peut être une ponctuation, un mot ou une sous-unité plus petite comme un morphème. Chaque token est repéré par un identifiant unique propre à chaque modèle. L'ensemble des tokens constitue le vocabulaire d'un LLM.

Clear Show example

Tokens	Characters
76	327

Un token (jeton en français) est l'unité de base utilisée par les modèles de langage pour modéliser un texte. Il peut être une ponctuation, un mot ou une sous-unité plus petite comme un morphème. Chaque token est repéré par un identifiant unique propre à chaque modèle. L'ensemble des tokens constitue le vocabulaire d'un LLM.


<https://platform.openai.com/tokenizer>

G. LLM et VLM

Les IA génératives

Type d'IA qui utilise des modèles relevant de l'apprentissage profond pour générer de manière autonome des contenus (texte, son, image, vidéo, etc.), souvent en répondant à des requêtes exprimées par des utilisateurs humains (*prompts*).

Plusieurs approches techniques au fil du temps.




Grands modèles de langue (LLM)

Modèles d'intelligence artificielle utilisés pour modéliser et traiter le langage humain. Ils sont appelés « **grands** » parce que ces types de modèles sont entraînés sur de grands ensembles textuels provenant de différentes sources et sont constitués de centaines de millions à des milliards de paramètres qui définissent le comportement du modèle.

Leurs paramètres affectent de manière significative les capacités langagières et d'acquisition de connaissances du modèle. Par exemple, GPT-3 a été formé avec environ **175 milliards de paramètres**. Son concurrent, LLaMA 2, a été entraîné avec **70 milliards de paramètres**.

Le dernier né DeepSeeck serait entraîné avec **671 milliards de paramètres**.
GPT 4.5 : > 1000 milliards ?

<https://informationisbeautiful.net/visualizations/the-rise-of-generative-ai-large-language-models-llms-like-chatgpt/>



BERT (Bidirectional Encoder Representations from Transformers)

Le modèle BERT (*Bidirectional Encoder Representations from Transformers*) est un modèle de traitement du langage naturel (NLP) développé par Google en 2018.

Contrairement aux modèles précédents qui lisaient le texte de gauche à droite ou de droite à gauche, BERT lit dans les deux sens en même temps. Cela permet une meilleure compréhension du sens des mots selon leur contexte.

BERT est basé sur l'architecture **Transformer** (2017), qui utilise :

- *Self-attention* : chaque mot du texte regarde les autres mots pour comprendre ses relations.
- Encoder uniquement : BERT n'utilise que la partie « encodeur » du Transformer (GPT utilise le décodeur).

BERT est d'abord pré-entraîné sur de grandes quantités de texte avec deux tâches principales :


- *Masked Language Modeling* (MLM) : certains mots sont masqués et le modèle doit les prédire.
- *Next Sentence Prediction* (NSP) : le modèle doit prédire si une phrase suit logiquement une autre.

["Au coeur des LMM sans les maths", Jean-Thierry Graveaud](#)
[Comment une IA générative crée-t-elle du texte ?](#)
[Le modèle Transformer: un « couteau suisse » pour le traitement](#)
[automatique des langue.](#) François Yvon


BERT

- Compréhension profonde du contexte grâce à la bidirectionnalité.
- Très performant sur de nombreuses tâches TAL
- Base pour de nombreux modèles dérivés comme RoBERTa, ALBERT, DistilBERT.

[Le modèle Transformer: un « couteau suisse » pour le traitement automatique des langues.](#) François Yvon Université Paris-Saclay, CNRS, LISN



ATELIER : entraînement BERT



The screenshot shows the 'BERT Demo' page on the Cognitive Computation Group website. The page has a blue header with the group's logo and name. A navigation bar below the header contains links for News, Research, People, Software, Demos, Publications, For Group Members, Blog, and Resources. The 'Demo' section is highlighted in a dark blue bar. The main content area features the title 'BERT Demo' with 2,962 views. It includes a paragraph explaining that BERT is a transformer-based pretrained language model released by Google Research in late 2018, and that this demo illustrates its pre-training objectives. There are two links: one to the GitHub repository and another to the original NAACL paper. At the bottom, there are two dropdown menus: 'bert-base-uncased' and 'Example Inputs'. Below these are two text input fields: 'Input sentence (with at least one mask '@' token)' and '(Optional) second sentence'.

COGNITIVE COMPUTATION GROUP

News Research People Software Demos Publications For Group Members Blog Resources

Demo

BERT Demo

2,962 views

BERT is a transformer-based pretrained language model that was released in late 2018 by Google Research. BERT Encoder Representations from Transformers. This demo demonstrates the two (pre-)training objectives of BERT -- masked language modeling and next sentence prediction.

[Click here](#) for the GitHub repository.

Here is the [original NAACL paper](#) introducing BERT.

bert-base-uncased Example Inputs


Input sentence (with at least one mask '@' token)

(Optional) second sentence

https://cogcomp.seas.upenn.edu/page/demo_view/BERT

GPT : *T* pour *Transformer*

L'idée centrale du modèle Transformer (2017) consiste à faire dépendre la représentation d'un mot de tous les mots de son contexte gauche, tout en faisant disparaître la récurrence du calcul afin de pouvoir le paralléliser.



Les encodage du contexte gauche réalisés par divers modèles de langue : les modèles n-gramme (FF) n'encodent qu'un contexte réduit; les modèles RNN accordent plus d'importance aux mots les plus proches; les Transformers apprennent un encodage qui traite à égalité tous les mots du contexte.

- modèles autorégressifs (GPT)
- modèles bidirectionnels (BERT)

["Au coeur des LMM sans les maths", Jean-Thierry Graveaud](#)

[Comment une IA générative crée-t-elle du texte ?](#)

[Le modèle Transformer: un « couteau suisse » pour le traitement automatique des langues, François Yvon](#)

Transformer et vectorisation

Tokenization (découpage en jetons)

Ecrit une histoire. → Ecrit une histoire .

Embedding (vectorisation)


Ecrit	→	2.77	-0.52	...	-1.07
une	→	0.82	0.48	...	0.15
histoire	→	-1.71	1.36	...	0.07
.	→	1.35	-1.42	...	-2.57

Positional encoding (encodage positionnel)


Ecrit	→	2.77	-0.52	...	-1.07	1
une	→	0.82	0.48	...	0.15	2
histoire	→	-1.71	1.36	...	0.07	3
.	→	1.35	-1.42	...	-2.57	4

Après les étapes précédentes (tokenization, plongement), le modèle *Transformer* crée une série de blocs empilés les uns sur les autres, chacun d'entre eux étant constitué de deux parties principales :

- un mécanisme *d'attention* : il permet de repérer les relations entre les différents *tokens*, en tenant compte du contexte ;
- un réseau de neurones *feedforward* : il s'agit d'un réseau de neurones traditionnel qui traite les informations et effectue des prédictions.



ATELIER : Transformer




<https://poloclub.github.io/transformer-explainer/>

Un paramètre important : la température

La température d'un modèle détermine à quel point un **modèle peut être "créatif"**.

Avec une température de 0, un LLM produira à chaque fois la donnée ayant la plus grande probabilité.

Selon la tâche, on aura donc envie de modifier la température : plus faible pour des tâches où on a besoin de résultats basé sur des faits (traduction, Q&A, etc), et plus haute pour de l'écriture créative.



ATELIER : Température de modèle

The screenshot shows the VittaScience IA interface. At the top, there's a navigation bar with links: Programmer, IA, Ressources, Classe, Matériel, and Premium (marked as NEW). Below this is a header with 'vitta science' and a 'Nouveau projet' button. The main chat area contains a system prompt: 'Tu es un assistant utile nommé 'VittaBot'. Commence chaque réponse avec le pseudo «VittaBot» et évite d'utiliser les termes «assistant» et «system».' followed by a user question: 'Moï: Pourquoi les feuilles changent-elles de couleur en automne ?'. The assistant's response is: 'VittaBot: Les feuilles changent de couleur en automne à cause de la diminution de la lumière du jour et des températures plus fraîches. Ces changements climatiques ralentissent la production de chlorophylle, le pigment responsable de la couleur verte des feuilles. Les autres pigments, comme les caroténoïdes (jaunes, oranges) et les anthocyanes (rouges, violets), qui étaient masqués par la chlorophylle, deviennent alors visibles.' To the right, the 'Paramètres' sidebar is open, showing 'Modèle: Mistral-small', 'Aléatoire' set to 25% (highlighted with a red circle), and 'Découvre les instructions'. Other settings include 'Tokens: 392', 'Mode: Texte', and 'Consommation: NEW'. At the bottom, there are buttons for 'Nettoyer', 'Régénérer', and 'Envoyer', along with a disclaimer: 'Les réponses générées par l'IA peuvent contenir des erreurs. Pensez à vérifier les informations importantes.'

vitta science

Programmer IA Ressources Classe Matériel Premium ^{NEW}

Nouveau projet + [Icons]

Tutoriel [Settings Icon]

Tu es un assistant utile nommé 'VittaBot'. Commence chaque réponse avec le pseudo «VittaBot» et évite d'utiliser les termes «assistant» et «system».

mistral-small-3-24b-instruct-2506 25%

Moï: Pourquoi les feuilles changent-elles de couleur en automne ?

VittaBot: Les feuilles changent de couleur en automne à cause de la diminution de la lumière du jour et des températures plus fraîches. Ces changements climatiques ralentissent la production de chlorophylle, le pigment responsable de la couleur verte des feuilles. Les autres pigments, comme les caroténoïdes (jaunes, oranges) et les anthocyanes (rouges, violets), qui étaient masqués par la chlorophylle, deviennent alors visibles.

Entrer une instruction ou charger un exemple

[Info] [User Icon]

[Trash] Nettoyer [Refresh] Régénérer [Send] Envoyer

Les réponses générées par l'IA peuvent contenir des erreurs. Pensez à vérifier les informations importantes.

Paramètres ▾

Modèle: Mistral-small ▾

Aléatoire 25% (highlighted with a red circle)

Découvre les instructions

Tokens 392

Montrer Masquer tokenIDs

Mode Texte Discussion

Consommation > NEW

Sources >

Utilisation ▾

<https://fr.vittascience.com/ia/text>


Agents conversationnels

Agent conversationnel (*chatbot*) : “Logiciel qui simule le dialogue en langage naturel avec l'utilisateur” (*Le Robert*)

Les chatbots classiques s'appuient sur des règles, des mots-clés et une logique déterministe, ce qui les rend simples et prévisibles, mais peu flexibles (ambiguïté, formulations imprévues).

Aujourd'hui, les agents conversationnels sont souvent basés sur un LLM (ChatGPT, Mistral Le Chat...), avec une adaptation du LLM au contexte d'un dialogue :

- prise en compte de l'historique des échanges,
- imitation des formes de dialogue humain,
- alignement avec des contextes culturels,
- sécurisation.



ATELIER : agent conversationnel




<https://www.perplexity.ai/>

Texte, image, vidéo, parole...

Dans le champ de l'IA générative, il existe des modèles capables de **générer des images, des vidéos, du son à partir d'une description textuelle**. Ces modèles ont été entraînés avec des données couplées avec des descriptions.

Pour les images : DALL-E, Midjourney, Stable Diffusion, etc. Pour les vidéos : Synthetia, InVideo AI, Sora, Veo 3, etc.




Modèles multimodaux (LMM)

Les LMM sont des modèles capables de traiter et d'interpréter plusieurs modalités de données (texte, image, image animée, son, parole...)

LVM = modèle langage/vision

Exemples : Pixtral, Gemini, CLIP...



Source : BnF


CLIP (*Contrastive Language-Image Pre-training*)

Modèle CLIP (OpenAI, 2021) : apprentissage d'un espace de représentation commun à partir de 400 M d'images du web et leurs légendes

- le modèle peut être opéré avec des requêtes en langage naturel
- large “connaissance visuelle”, utilisable en zéro-shot



1. Contrastive pre-training



<https://openai.com/research/clip>

- les textes sémantiquement identiques sont proches dans cet espace
- les images visuellement similaires sont proches dans cet espace
- idem pour les textes/images

Famille CLIP

CLIP (OpenAI, janvier 2021)

- Architecture duale vision + texte (par ex. Vision Transformer ou ResNet pour l'image, Transformer pour le texte).
- Perte contrastive softmax (InfoNCE) qui rapproche les paires correspondantes et éloigne les autres.

OpenCLIP : implémentation open-source de CLIP


- Rendre reproductible la formation de modèles CLIP sur des datasets publics plus larges et diversifiés (par ex. LAION-400 M).
- Inclure dans la même bibliothèque plusieurs familles de modèles multimodaux, pas uniquement CLIP (ex. CoCa, SigLIP, CLIPA, MetaCLIP...).

SigLIP (*Sigmoid Loss for Language-Image Pre-Training*, Google DeepMind, 2023) : variante qui modifie l'objectif d'entraînement de CLIP.

- Remplace la perte contrastive softmax traditionnelle par une perte sigmoid pairwise, simplifiant le calcul et réduisant la dépendance aux grandes tailles de lot lors de l'entraînement. La perte sigmoid traite chaque paire image-texte indépendamment, ce qui améliore l'évolutivité et l'efficacité de l'entraînement sans nécessiter de normalisation sur tout le batch. SigLIP dans OpenCLIP : OpenCLIP répertorie des modèles SigLIP (comme ViT-B-16-SigLIP et variantes de résolution)

CLIPA, SigLIP2 : stratégies d'entraînement spécifiques, multilinguisme, techniques de régularisation...

ATELIER : SAM 3




SAM (*Segment Anything*, Meta, 2023) :

<https://ai.meta.com/sam3/>

1. Choisir Create Image Cutouts
2. Charger une image ([exemple](#))
3. Essayer en détection d'objet, classification et OCR

<https://aidemos.meta.com/segment-anything/gallery>


ATELIER : Rechercher dans des images



<https://meru.robots.ox.ac.uk/gallica/>

OCR : modèles génératifs

Aujourd'hui, les modèles d'IA génératifs, dans leur variante LMM ou LVM, sont une alternative aux moteurs OCR, étant en capacité de traiter les modalités texte et image (voir infra).



Gemini
2.5 Flash

Mettre à niveau



Bonjour JP



je veux que tu transcrives le texte (en français) de cette page d'un livre numérisé

+ Outils

Des réviseurs humains lisent certaines discussions enregistrées afin d'améliorer l'IA de Google. Pour que les futures discussions ne soient pas lues, désactivez l'Activité dans les applications Gemini. Si ce paramètre est activé, ne saisissez aucune information que vous ne souhaiteriez pas que quelqu'un examine ou utilise. [Comment ça fonctionne](#)

Gérer l'activité Fermer

RELIQUES

ET

IMPRESSIONS

MA MÈRE (LA MARQUISE D'OSMOND)

« Lorsque je ne serai plus de ce monde, tu sauras alors seulement ce que tu as perdu ». Telle est la phrase que répétait souvent ma bonne et chère mère, lorsqu'elle me sentait rebelle à son influence et à ses sages conseils. Que de fois depuis je me suis répété ces touchantes paroles, car c'est seulement après sa mort que j'ai pu apprécier l'immensité de la perte que je venais de faire. L'enfant comme l'homme s'habitue trop facilement aux grandes qualités de ceux qui l'entourent, et, sans en comprendre l'intensité, il subit le reflet bienfaisant, in-

ATELIER : modèles génératifs et OCR



<https://gemini.google.com/>



H. Traiter les images à contenu textuel : OCR, HTR




Images et texte : OCR (*Optical Character Recognition*)

OCR : famille d'algorithmes ou modèles IA qui cherche à localiser et à transcrire des contenus textuels présents dans une image. Technologies CV + traitement du langage

Difficultés :

- ❑ Qualité de l'image
- ❑ Variabilité des typographies
- ❑ Grand nombre de systèmes d'écriture, de langues
- ❑ Langues peu dotées en ressources linguistiques

Note : champ considéré comme clos pour les langues européennes et les documents contemporains




Optophone, Fournier d'Albe (1913)



La petite histoire de l'OCR

1870-1930

Lecture audio
pour les aveugles



Optophone , Fournier d'Albe
(1913)

1930-1955

Applications
industrielles
(IRM, IBM)



Police Farrington B,
David H. Shepard (1952)

1955-1975

Lecteur Braille
portable,
poste,
banque...



Optacon, John Linvill
(1964)

1975-2000

Scanner+OCR,
premier OCR
multifonte




Reading Machine,
Ray Kurzweil (1974)

2015...

OCR
banalisé



Google Drive





Scan tent

[illegible]

1990, 1991 and 1992, the mean number of fish per minute was significantly less in the control than in the treated groups.

Redressement

OCR : suite d'étapes



OCR : suite d'étapes




Segmentation

charges. Il n'est pas besoin de vous en
coter des exemples : car telles gens
auoient de naissance vne lumiere &

cultiuée vns qui les y raçonn
beau- de present en singuli
tion vne multitude
d'un rien se sont es
charges. Il n'est pas



OCR : suite d'étapes




Reconnaissance du texte

Comment reconnaître les lettres ?


Modèles de bitmaps




Modèles de contours



Structure



Zones d'intérêt



- Extraction de caractéristiques image (« features ») ou de métriques et comparaison avec une base de référence
 - Aujourd'hui : approche par apprentissage machine

ATELIER : HTR (réseau neuronal convolutif)



Visualisation d'un réseau convolutionnel entraîné pour de la reconnaissance de chiffres manuscrits

https://adamharley.com/nn_vis/cnn/2d.html

HTR (*Handwritten Text Recognition*)

HTR : localiser et transcrire
des écritures manuscrites

Deux modalités pour la reconnaissance :

1. *Offline handwriting recognition*


Texte qui a déjà été écrit.

Exemple : manuscrit ancien

2. *Online handwriting recognition*

Reconnaissance en temps réel de texte écrit.

Exemple : sur une tablette




Pourquoi la reconnaissance de l'écriture manuscrite est complexe ?

- Chaque écriture est différente
- Variabilité des styles d'écriture au fil du temps
- Position variable des "lignes" de texte


Plateformes HTR

eScriptorium (INRIA)



<https://escriptorium.inria.fr/>

Transkribus (coopérative READ-coop)



<https://www.transkribus.org/>

ATELIER : HTR avec Transkribus



PlateformeUtilisationsCommunautéRessourcesLa coopForfaits & Prix

Connexion


Essai gratuit

FR


Language: French

HandwrittenPrint

AI model: Transkribus French Model 1 ⓘ



La Gounod (ch) 144
Londres. Tariffock teuje-
Tavissock Sgnave-
3
31 Juie 17
mon Jean cheri,
Je ne savait où t'atresser un mot
pour le premier de l'An. Une lettre
du ta mamsan s'affrend le matin que
tu frras demain à la maison. J'accoure
t'y ambrasser, mon cher bien asme fils
avec cette tendresse qui est toujours près ée
ton malgve la diffance qui nous separe.
Le t'esore en un blsc. tout les vieux



La Gounod (ch) 144
Londres. Tariffock teuje-
Tavissock Sgnave-
3
31 Juie 17
mon Jean cheri,
Je ne savait où t'atresser un mot
pour le premier de l'An. Une lettre
du ta mamsan s'affrend le matin que
tu frras demain à la maison. J'accoure
t'y ambrasser, mon cher bien asme fils
avec cette tendresse qui est toujours près ée
ton malgve la diffance qui nous separe.
Le t'esore en un blsc. tout les vieux




Upload another image PDF Doc Copy to clipboard



<https://www.transkribus.org/fr/langues/fran%C3%A7ais>

ATELIER : OCR Arena



Comparateur d'OCR

1. Aller sur l'onglet Playground
2. Charger une image ([exemple](#))
3. Choisir 2 modèles
4. Comparer


<https://www.ocrarena.ai/battle>

I. Ingénierie de l'IA

Méthodes


Voir aussi [CNRS-FIDLE](#)

Entrainement de modèles



Ensemble de données

Le modèle est évalué sur les données de validation après chaque epoch : permet de mesurer sa capacité à généraliser à des données qu'il n'a pas vues pendant l'apprentissage.




Le jeu de validation sert à déterminer les valeurs optimales de paramètres (hyperparamètres tels que :

- le taux d'apprentissage (learning rate),
- la profondeur du réseau, le nombre d'unités ou de couches,
- la régularisation, la taille des batchs, etc.

Il sert donc de base pour comparer différentes configurations de modèle.

Algorithme de rétropropagation du gradient

- Algorithme itératif
- Initialisation des poids aléatoires
- Choix de la fonction de coût
- Itération sur des lots de données d'apprentissage (*epoch*)
- Mise à jour des poids
- Arrêt de la convergence





Algorithme de rétropropagation du gradient

Méthode

(a) on définit une fonction de coût, (*loss*), $\ell(\hat{y}_i, y_i^*)$ qui modélise la pénalisation entre la sortie prédite par le réseau et la sortie donnée par la supervision

(b) on minimise la fonction de coût sur l'ensemble d'apprentissage $(\mathbf{x}_i, \mathbf{y}_i^*)$, soit la moyenne des fonctions de coût sur les différents exemples d'apprentissage (*gradient* de la fonction de coût)


$$\mathcal{L}(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \ell(\hat{y}_i, y_i^*)$$



Intuition

- *Forward pass* : le réseau fait sa prédiction.
- *Backward pass* : l'erreur est "propagée en arrière" pour calculer l'impact de chaque poids sur la perte.
- *Mise à jour* : les poids sont ajustés pour réduire l'erreur.
- Descente de gradient : algorithme d'optimisation qui trouve les meilleurs poids en suivant la "descente" la plus raide de la fonction de perte.

ATELIER : Algorithme de rétropropagation du gradient



<https://saricmilos.com/neural-networks-playground/>

Fine-tuning (affinage) d'un modèle

Méthode d'entraînement qui consiste à **ajuster certains paramètres du modèle** pour l'adapter à une tâche spécifique sans perdre les connaissances préalables acquises lors de l'entraînement initial.

L'idée centrale repose dans la capacité du modèle à se spécialiser à de nouveaux domaines tout en conservant sa capacité à généraliser. Le *fine-tuning* (ajustement) permet d'ajuster les poids des connexions entre les neurones pour qu'ils soient plus adaptés à la nouvelle tâche sans perturber significativement les connaissances pré-existantes.


Pourquoi c'est intéressant ?

1. Eviter de consommer beaucoup de ressources à chaque fois qu'on a besoin d'un modèle pour une tâche spécifique (moins de temps d'entraînement et moins cher)
2. Comme les modèles ont déjà appris des caractéristiques génériques, ils sont plus performants à apprendre des tâches plus précises
3. On peut obtenir des bons résultats même si on n'a pas beaucoup de données d'entraînement

Apprentissage par transfert (*transfert learning*)

L'apprentissage par transfert gèle la plupart du modèle pré-entraîné et n'entraîne que les couches finales, alors que l'affinage met à jour partie ou totalité des couches du modèle pré-entraîné afin de mieux l'adapter à la nouvelle tâche.

L'affinage et l'apprentissage par transfert (*transfert learning*) aident les modèles à utiliser ce qu'ils ont appris d'une tâche pour mieux se comporter dans une autre tâche. Bien que les deux puissent sembler similaires, ils diffèrent dans leur application et dans leur fonctionnement.




Apprentissage par transfert
(cas de l'atelier Iris)


Affinage

Apprentissage par transfert : exemple

Classification avec un réseau de neurones convolutionnel
pour catégoriser des types de documents ou d'illustrations



Cas d'usage :
bibliothèque



Cas d'usage :
archives



Apprentissage autosupervisé, semi-supervisé

Dans l'approche **autosupervisée** (*Self-Supervised Learning*), le modèle crée lui-même ses données d'entraînement à partir de données non étiquetées.

Exemple : autoencodeurs, transformers, vision par ordinateur (CLIP...).

Avantage : Permet d'utiliser de grandes quantités de données sans annotation


L'apprentissage **semi-supervisé** est une approche hybride qui utilise une petite quantité de données étiquetées puis une grande quantité de données non étiquetées. Un modèle pré-entraîné sur les données étiquetées (*amorçage*) prédit ensuite sur le jeu de données non étiquetées. L'itération suivante d'entraînement utilise toutes les données étiquetées (seuls les exemples prédits avec une confiance élevée dans la prédiction sont ajoutés).

Apprentissage par renforcement humain (RLHF)

Dans cette approche (RLHF, *Reinforcement Learning from Human Feedback*), des annotateurs humains évaluent plusieurs réponses du modèle. A partir de ces réponses, on entraîne un autre **modèle de récompense** pour que le modèle soit optimisé pour maximiser ce score.

Objectif : rendre les réponses du modèle

- plus utiles,
- plus naturelles,
- plus sûres (respect de règles d'alignement)




Apprentissage en contexte

L'apprentissage en contexte (*In-Context Learning*, ICL)) désigne la capacité d'un modèle de langage à apprendre à effectuer une tâche **uniquement à partir d'exemples donnés dans le prompt**, sans modification des paramètres du modèle. Le modèle « apprend » à la volée à partir du contexte fourni, plutôt que par un entraînement classique.

Variantes :

- *Zero-shot* : on fournit la tâche seulement, sans exemple. Exemple : « Traduire 'Dog' en français. »
- *One-shot* : on fournit un seul exemple avant la tâche
- *Few-shot* : on fournit plusieurs exemples pour aider le modèle à comprendre la tâche.

ATELIER : apprentissage en contexte



<https://chat.mistral.ai/>

Prompt

Génère un couplet rimé sur un arbre en suivant ces exemples :

Entrée : « chat » Sortie : Le chat s'étire au soleil levant, Ses yeux dorés brillent en rêvant.

Entrée : « ciel » Sortie : Le ciel s'habille de bleu profond, Les nuages y dansent en rond.

Entrée : « arbre » Sortie :

Techniques d'apprentissage

- **Descente de gradient** : algorithme classique pour minimiser la fonction de perte. Variantes : Stochastic GD, Mini-batch GD, Adam, RMSProp.
- **Régularisation** : pour éviter le surapprentissage.
 - L1, L2 (pénalisation des poids)
 - *Dropout* (désactivation aléatoire de neurones)
 - *Early stopping* (arrêt anticipé)
- **Augmentation de données** : augmenter la taille des données par transformations
- **Normalisation / Standardisation** : mise à l'échelle des données pour améliorer la convergence.
- **Learning Rate Scheduling** : adapter le taux d'apprentissage au fil du temps pour stabiliser l'entraînement.
- **Batch Normalization** : stabiliser et accélérer l'entraînement dans les réseaux profonds.

Problèmes courants

Surapprentissage (*overfitting*)

Symptômes : Très bonne performance sur le jeu d'entraînement, mauvaise performance sur le test.

Causes : Modèle trop complexe, trop d'itérations, peu de données.

Solutions :

- Augmenter la taille du dataset
- Regularization (L1/L2, dropout)
- Early stopping
- Simplifier le modèle

Sous-apprentissage (*underfitting*)

Symptômes : Performance faible sur train et test.

Causes : Modèle trop simple, features insuffisantes.


Solutions :

- Ajouter des features pertinentes
- Complexifier le modèle
- Entraîner plus longtemps

Note : la qualité de **généralisation** est l'opposée du surapprentissage.

Surapprentissage

Courbe de perte symptomatique



Causes :

- L'ensemble d'entraînement ne représente pas de manière adéquate les données réelles (ni l'ensemble de validation ni l'ensemble de test).
- Modèle trop **complexe**

Complexité

Une approche permettant de simplifier un modèle consiste à pénaliser les modèles complexes, c'est-à-dire à forcer le modèle à devenir plus simple pendant l'entraînement. La pénalisation des modèles complexes est une forme de **régularisation**.

Les modèles axés uniquement sur la minimisation des pertes ont tendance à surajuster. Un meilleur algorithme d'optimisation de l'entraînement **minimise une combinaison de perte et de complexité** (mais perte et la complexité sont généralement inversement proportionnelles). En règle générale, la régularisation consiste à réduire marginalement la précision de l'entraînement pour augmenter la capacité à généraliser :

- supprimer des poids inutiles
- réduire les grandes valeurs de poids

Problèmes courants

Données biaisées ou bruitées

- Peut conduire à des modèles injustes ou instables.
- Vérification de la qualité et équilibrage des données essentiel.

d) Vanishing / Exploding Gradient (pas de convergence)

- Problème surtout dans les réseaux profonds.
- Solutions : Initialisation appropriée, activation ReLU, batch normalization.

e) Choix de métriques inadaptées

Utiliser une métrique cohérente avec le problème (ex : précision seule peut être trompeuse pour des classes déséquilibrées).


Bonnes pratiques

- **Split dataset** : train / validation / test (ex : 70/15/15)
- **Validation croisée** : Permet une estimation plus robuste de la performance.
- **Hyperparameter tuning** : Grid search, Random search, ou Bayesian optimization.
- **Monitoring** : Suivi de la perte et des métriques sur train/validation.

Données déséquilibrées ?

Un modèle doit apprendre deux choses :

1. À quoi ressemble chaque classe ?
i.e à quelle classe correspondent les valeurs des caractéristiques ?
2. La fréquence de chaque classe, c'est-à-dire la distribution relative des classes.



Pas assez de rose pour apprendre 1 !

Données déséquilibrées : méthode

Étape 1 : Sous-échantillonner la classe majoritaire

La classe minoritaire est mieux représentée.




Étape 2 : Le sous-échantillonnage introduit un biais de prédiction en montrant au modèle un monde artificiel où les classes sont plus équilibrées que dans le monde réel. Pour corriger ce biais, il faut "surpondérer" la classe majoritaire : la perte sur un exemple de classe majoritaire est traitée plus sévèrement.

Loss for a bad
prediction on
minority class 🌹
✖

Loss for a bad
prediction on
majority class 🌻
✖ ✖ ✖ ✖ ✖
✖ ✖ ✖ ✖ ✖
✖ ✖ ✖ ✖ ✖
✖ ✖ ✖ ✖ ✖
✖ ✖ ✖ ✖ ✖


Validation croisée

Méthode K-folds : diviser le jeu de données en échantillons ou en blocs. Entraîner le modèle pour chaque fold. La moyenne des scores représente la métrique de performance du modèle. Ainsi, l'ensemble des données apparaîtra aussi bien dans les données d'entraînement que dans les données test.



Techniques d'optimisation

- **LoRA** (*Low-Rank Adaptation*) : affiner des modèles pré-entraînés à de nouvelles tâches ou données sans avoir à réentraîner l'intégralité du modèle. LoRA se concentre sur la modification d'un sous-ensemble de paramètres plus petit (matrices de rang inférieur) afin de réduire les coûts



Techniques d'optimisation

- **QLoRA** : variante de LoRA qui incorpore la quantification afin de réduire davantage l'empreinte mémoire et les ressources de calcul nécessaires pendant l'entraînement.
- La quantification d'un modèle de fondation est une méthode qui permet de réduire les ressources nécessaires au stockage d'un modèle de fondation en convertissant le type de données des poids du modèle en un type de données moins précis (flottant 16 -> entier 4)

Techniques d'optimisation

Distillation : méthode permettant de transférer le savoir d'un grand modèle (*teacher*) vers un modèle plus petit (*student*). L'objectif est de produire un modèle plus léger et plus rapide à l'inférence tout en conservant une grande partie des performances du modèle initial.

Entraînement du teacher : On entraîne un modèle complexe sur les données originales pour atteindre des performances élevées.

Extraction des "soft labels" : au lieu de se limiter aux labels corrects ("chien" ou "chat"), on utilise les probabilités prédictives du teacher sur chaque classe. Ces probabilités reflètent les connaissances implicites du modèle (le teacher peut prédire 80 % "chien", 15 % "loup", 5 % "renard" pour une image de chien).

Entraînement du student :

Le modèle student apprend à reproduire les sorties du teacher. La fonction de perte combine :

- La perte classique sur les labels réels.
- La perte sur les "soft labels" du teacher

Techniques d'optimisation


Curriculum learning : (apprentissage par curriculum) s'inspire de la manière dont les humains et les animaux apprennent : on commence par des tâches simples pour progressivement passer à des tâches plus complexes. L'idée est de structurer l'entraînement d'un modèle de manière graduelle, plutôt que de présenter immédiatement toutes les données de façon aléatoire.

On définit un ordre de difficulté pour les exemples ou les tâches.

On commence par les exemples les plus faciles, que le modèle peut apprendre rapidement.

Au fur et à mesure que le modèle s'améliore, on introduit des exemples plus difficiles.

Cette approche aide le modèle à construire progressivement ses capacités, à éviter de se bloquer sur des exemples trop complexes dès le début et à améliorer la convergence lors de l'entraînement.



Ingénierie de l'IA

Pratiques



Prompting

Objectif : rédiger un prompt clair et efficace.

- Clarté : éviter les ambiguïtés.
- Concision : donner les informations essentielles.
- Contexte : fournir le contexte nécessaire pour guider la réponse.

Méthodes :

- **Prompt simple, guidé, avec exemple,**
- **Instructions étape par étape** (*step-by-step prompting, chain of thought*)
- **Rôle et style** (*instruction-based prompting*) demander à l'IA d'adopter un rôle
- Prompting avec contraintes ou templates sur le format de sortie (cf. Pydantic)
- **Self-ask / ReAct** : Le modèle pose des questions à lui-même ou adopte une démarche « Question → Recherche → Réponse »

A la croisée de l'IA générative et de la recherche d'information : le RAG (*Retrieved Augmented Generation*)


Technique qui réunit LLM et recherche d'information (*Information Retrieval* : indexer et retrouver des documents).

Principe clé : L'IA ne se contente pas de générer du texte à partir de sa mémoire ; elle récupère des informations pertinentes dans une base de données locale avant de générer sa réponse.

Etapes :


1. Découpage des contenus en morceaux
2. Vectorisation des contenus et stockage dans une base vectorielle
3. Vectorisation de la requête utilisateur
4. Comparaison avec les vecteurs de la base
5. Formation d'une liste de résultats
6. Envoi de la liste à un LLM pour reformulation, analyse, résumé, etc. + interaction avec l'utilisateur

RAG : principe



RAG : outillage


- NotebookLM (Google)
- OpenNotebook : <https://www.open-notebook.ai/>
- SurfSense : <https://www.surfsense.com/>
- AnythingLLM : <https://anythingllm.com/>
- NotebookLlama : <https://notebooklama.com/>
- ...



ATELIER : RAG

The screenshot shows the DEWEY interface with three main panels: Sources, Discussion, and Studio.

- Sources:** Displays a document titled "bpt6k6307610j.txt". A "Guide sur la source" (Guide on the source) is visible, providing details about the document's origin and content. The text describes a collection of historical documents, including literary works, biographies, legislative texts, and religious poetry, published in the 19th century. It also mentions the author, Carlo Du Monge, and the publisher, Ernest d'Hervilly.
- Discussion:** Features a "DEWEY" header and a section for "48 sources". The text describes the collection's focus on historical documents, including literary works, biographies, legislative texts, and religious poetry, published in the 19th century. It also mentions the author, Carlo Du Monge, and the publisher, Ernest d'Hervilly.
- Studio:** Contains a sidebar with various tools for document management, including "Résumé", "Carte", "Fiche", "Info", "Table", "Quiz", "Rapp", and "Pré". A button "Ajouter une note" (Add a note) is also present.



<https://notebooklm.google.com/>

ATELIER : RAG Gallica



Preuve de concept :

- ILLUIN Technology
- étudiants CentraleSupélec

<https://f25-p2-rag-bib.k8s.paris-digital-lab.fr/>

IA agentique

L'IA agentique repose sur des **agents autonomes** capables de percevoir, décider et agir dans un environnement.
Un Agent = une entité dotée de capacités cognitives : perception, raisonnement, planification, exécution.

Caractéristiques principales d'un agent :

- **Autonomie** : prend des décisions sans intervention humaine continue.
- **Réactivité** : adapte son comportement aux changements de l'environnement.
- **Proactivité** : poursuit des objectifs de manière planifiée.

Protocoles techniques :


- Le protocole **A2A** (*Agent2Agent*) permet aux agents IA de se connecter à d'autres agents.
- Le protocole **MCP** (*Model Context Protocol*) permet aux agents IA de se connecter à des outils/API.

A2A

A2A (Google, 2025) permet à différentes applications ou services d'échanger des données ou des instructions pour alimenter des processus intelligents. Le protocole se concentre sur la collaboration entre agents.

Concepts :

- client A2A
- serveur A2A
- fiche d'agent
- tâche
- message
- artefact





MCP


MCP (Anthropic, 2024) est un protocole standard ouvert conçu pour permettre aux modèles de se connecter à des sources de données, des outils et des services externes de manière standardisée.

MCP fonctionne selon une architecture client-serveur :

- un **serveur MCP** expose des données, des fonctions ou des outils ;
- un **client MCP** (intégré dans une application IA) envoie des requêtes et reçoit des réponses via un format standard (JSON-RPC 2.0) ;
- l'**hôte MCP** est l'application qui orchestre l'ensemble et intègre le modèle de langage, souvent un assistant IA (Claude, ChatGPT...) ou un IDE.




MCP et A2A




MCP : application

Aide au catalogage (Bibliothèque nationale de Suède) :

- Le client MCP Ordo (Gemma 3) est chargé de faire de l'indexation sujet d'ouvrages
- Il utilise les services de serveurs MCP : calcul de candidats sujet, extraction de métadonnées, recherche dans une base vectorielle, appel à l'arbitrage d'un catalogueur professionnel



ATELIER : MCP Gallica



https://github.com/Kryzo/mcp-bibliotheque_nationale_de_France

Low-code/No-code

Low-code et **No-code** sont des approches de développement logiciel qui permettent de créer des applications avec peu ou pas de codage traditionnel. Elles s'adressent à différents profils d'utilisateurs : des développeurs professionnels aux utilisateurs métiers (citizen coding) sans compétences techniques avancées.

- **Low-code** : nécessite un minimum de programmation. Idéal pour les développeurs qui veulent accélérer le développement tout en conservant la possibilité de personnaliser le code.
- **No-code** : ne nécessite aucune programmation. Utilise des interfaces visuelles (drag-and-drop, menus, configurations) pour construire des applications.

L'approche low-code/no-code démocratise le développement logiciel, permet une mise en œuvre rapide et facilite la collaboration entre équipes techniques et métiers, mais il reste limité pour des systèmes complexes et génère des enjeux opérationnels :

- **Dépendance à la plateforme** : migration vers d'autres systèmes, maintien en condition opérationnel, personnalisation et intégration limitées au SI
- **Performance** : certaines plateformes peuvent générer un code moins optimisé.
- **Évolutivité** : pour les applications complexes, MCO
- **Gouvernance** : shadow IT, sécurité, données

Low-code/No-code : approches

Fonctionnalités :

- Concepteurs visuels d'applications
- Outils d'automatisation de workflows
- Tableaux de bord pour l'analyse et le reporting
- API et intégration avec des ressources tierces
- Intégration de l'IA

Exemples :

- Microsoft Power Apps
- n8n, Dataiku
- Zapier, Make
- Notion, Airtable, Coda
- Aide au développement :
 - Github Copilot (GitHub, OpenAI)
 - JetBrains IntelliJ IDEA + CodeWhisperer
 - Codeium
 - Google Antigravity
 - Claude Code
 - OpenAI Codex
 - Cursor...

ATELIER : Google Antigravity

The screenshot displays the Google Antigravity AI interface within a web browser. The top bar shows 'Agent Manager' and 'Open Editor'. The main workspace is titled 'Classification_images / Check Python Script Consistency'. On the left, a sidebar shows a 'Created Task' with a 'View' button. The task details include 'Project Exploration' (analyzing `extract_dim.py` and `plot_data.py` for issues like hardcoded API keys and bugs), 'Files Edited' (an 'Implementation Plan'), and 'Progress Updates' (a list of steps: 1. Reading Python scripts, 2. Analyzing `extract_dim.py` and `plot_data.py`, 3. Creating implementation plan). Below this, a summary states: 'I have analyzed the scripts and found some issues. Most notably a hardcoded API key and some fragile code in `plot_data.py`. I have created a plan to fix these. Please review the implementation plan.' An 'Implementation Plan' section shows a button to 'Open' the plan and a 'Proceed' button. The main area on the right is titled 'Project Consistency and Quality Improvements' and contains a 'User Review Required' section. This section highlights an 'IMPORTANT Security Risk' (hardcoded API key for Mistral) and a 'WARNING Bug in `plot_data.py`' (a `csv.reader` object attached to a closed file). Below this, 'Proposed Changes' are listed: 1. Security: Replace hardcoded `MISTRAL_API_KEY` with `os.environ.get("MISTRAL_API_KEY")`. 2. Refactoring: Refactor `read_csv_data` to return a list of paths instead of modifying a global. 3. Refactoring: Pass `file_paths` and `output_file` as arguments to `extract_image_dimensions`. 4. Consistency: Ensure standard import order. At the bottom, a chat input field says 'Ask anything, @ for context' and shows the current model is 'Gemini 3 Pro (High)'.

Classification_images / Check Python Script Consistency

Created Task View

Project Exploration

I have analyzed `extract_dim.py` and `plot_data.py`. I found several issues including a hardcoded API key, reliance on global variables, and a bug in `plot_data.py` regarding file handling. I am now creating a plan to address these.

Files Edited

Implementation Plan Task

Progress Updates Expand all

- 1 Reading Python scripts
- 2 Analyzing `extract_dim.py` and `plot_data.py`
- 3 Creating implementation plan

I have analyzed the scripts and found some issues. Most notably a hardcoded API key and some fragile code in `plot_data.py`. I have created a plan to fix these. Please review the implementation plan.

Implementation Plan Open Proceed

Plan to improve consistency, security, and code quality in Python scripts.

Project Consistency and Quality Improvements

I have analyzed the Python scripts `extract_dim.py` and `plot_data.py`. I found consistency issues, code quality problems, and a security risk.

User Review Required

IMPORTANT

Security Risk: `extract_dim.py` contains a hardcoded API key for Mistral. This should be moved to an environment variable.

WARNING

Bug in `plot_data.py`: The `read_csv_data` function returns a `csv.reader` object that is attached to a closed file. While the script currently works due to global variable usage, this is fragile and incorrect.

Proposed Changes

I propose to refactor both scripts to remove global variables, fix bugs, and improve consistency.

`extract_dim.py`

- ☐ **Security:** Replace hardcoded `MISTRAL_API_KEY` with `os.environ.get("MISTRAL_API_KEY")`.
- ☐ **Refactoring:** Refactor `read_csv_data` to return the list of paths instead of modifying a global.
- ☐ **Refactoring:** Pass `file_paths` and `output_file` as arguments to `extract_image_dimensions`.
- ☐ **Consistency:** Ensure standard import order.

Ask anything, @ for context

+ Planning Gemini 3 Pro (High)

<https://antigravity.google/>

MLOps (*Machine Learning Operations*)

DevOps : approche méthodologique visant à rapprocher les équipes de développement logiciel (Dev) et d'opération (Ops) pour améliorer la collaboration, l'automatisation, et la livraison continue de logiciels.

- Automatisation des processus : intégration continue, déploiement continu (CD), tests automatisés
- Amélioration de la collaboration entre développeurs et opérationnels
- Réduction des cycles de livraison et amélioration de la qualité logicielle.

MLOps : extension de la philosophie DevOps, adaptée au cycle de vie des projets d'apprentissage machine. DevOps s'intéresse à la livraison de logiciels, MLOps s'occupe de la livraison de modèles de ML :

- préparation des données et pipelines de données automatisés
- entraînement et versioning des modèles
- déploiement continu de modèles
- surveillance des modèles en production
- reproductibilité et gouvernance des modèles



Quels usages en bibliothèque ?



Aide au catalogage

- Catalogage courant
- Collections nées numériques
- Collections “oubliées” ou décrites





Catalogage courant



Rétrocatalogage

KBR :

- Scan de la page de titre d'ouvrages imprimés
- Analyse d'image (détection d'objets)
- Génération de données structurées (MARC)
- Avec Microsoft 365 Power Automate




Indexation sujet

ABES : indexation RAMEAU

- “classification multilabel extrême” (+100k concepts)
- plusieurs approches (apprentissage supervisé, LLM...), plusieurs modalités d'évaluation
- expérimentation in vivo

Recherche sémantique dans une base vectorielle
(modèle de sentence embedding / algorithmes
intégrés dans le logiciel ANNIE, BN Finland)

Provenance des modifications des notices
après appel du service




Classification disciplinaire

BN Norvège, BN Suède : indexation Dewey

- avec apprentissage supervisé

Algorithm	Precision, title only	Precision, title and subjects	Precision, all records	nDCG
Lexical	5.17%	16.42%	13.63%	0.2464
SVC	45.74%	66.24%	61.15%	0.7380
fastText	45.80%	64.01%	59.49%	0.7378
Omikuji	46.88%	65.49%	60.88%	0.7445
LSFO ensemble	50.66%	66.88%	62.91%	0.7625
Source(s): Authors' own creation				

Table 2.
Precision@1 of the five
algorithms on the
three-digit DDC
classification task



Classification décimale Dewey

Bibliothèque nationale de France

- Dewey : plan de classement [Gallica](#) (2-3 indices)
- Utilisation d'un LLM

BNF | Gallica | Assistant de Classification Dewey

Objectif: Choisissez la meilleure classification Dewey parmi les suggestions du modèle.
Cliquez sur une option puis sur "Soumettre et passer au suivant".

🔍 Légende des codes Dewey au deuxième indice.

Légende - Sciences				Légende - Techniques			
Code	Libellé	Code	Libellé	Code	Libellé	Code	Libellé
50	Sciences:Généralité	55	Sciences de la terre	60	Techniques:Généralités	65	Gestion
51	Mathématiques	56	Paléontologie	61	Médecine	66	Chimie
52	Astronomie	57	Biologie	62	Ingénierie	67	Industrie
53	Physique	58	Botanique	63	Agriculture	68	Artisanat
54	Chimie	59	Zoologie	64	Vie domestique	69	Construction

Titre

Choisissez la meilleure classification Dewey

processing : 112.4s

Table des matières

Soumettre et passer au suivant

- 10, Philosophie et psychologie:Généralités, Philosophie et psychologie
- 11, Métaphysique, Philosophie et psychologie
- 12, Épistémologie, Philosophie et psychologie
- 13, Ésotérisme, phénomènes paranormaux, Philosophie et psychologie
- 14, Écoles philosophiques, Philosophie et psychologie
- 15, Psychologie, Philosophie et psychologie
- 16, Logique, Philosophie et psychologie
- 17, Éthique, Philosophie et psychologie
- 18, Philosophie antique, médiévale, Philosophie et psychologie
- 181**, Philosophie orientale, ancienne et moderne, Philosophie et psy.
- 189**, Philosophie du Moyen Âge, Philosophie et psychologie



Vous êtes en France. Vous êtes un expert en classification DDC dans les Sciences et Techniques. Lisez les informations données, puis, à partir du guide, choisissez 2 classifications DDC différentes possibles.

Voici le guide contenant les noms de catégories et leur code DDC correspondant : {guide}

Voici les informations à lire :

Titre : {title}\n

Table des matières : {toc[:2000]}

Retournez les deux réponses sous forme d'une liste d'objets DDC avec leur code et une justification rédigée en une phrase complète.

Aide au catalogage de plaques argentiques par identification de reproductions dans la presse (BnF)


1. Numérisation
2. Recherche de similarité dans la presse LMM
3. Identification d'une reproduction
4. Génération de légende, extraction OCR LMM, OCR, LLM
5. Création d'une prénotice avec les informations extraites LLM



numérisation



reproduction



légende,
OCR

Prénotice




Décrire de nouvelles collections



Catalogage du dépôt légal numérique


Bibliothèque nationale du Luxembourg

- indexation de monographies numériques
- assemblage de modèles IA, fine tuning d'un LLM



Apprentissage sur des paires
image/notice MARC

Catalogage du dépôt légal numérique



Archives audiovisuelles

43% des fonds du dépôt légal quasi non signalé

2,5 M d'heures de télévision retranscrites par mois avec Whisper IA (100 000 heures/mois)



Recherche lexicale plein texte dans les transcriptions (Nautilus)

Recherche assistée par IA (recherche sémantique ou hybride)

<https://www.actuia.com/actualite/lancement-de-data-ina-fr-lina-ouvre-ses-archives-audiovisuelles-au-grand-public/>



data.ina.fr



Inventorier/cataloguer

Aide au catalogage de collections d'affiches :

- Recherche d'exemplaires déjà numérisés
- Recherche de doublons
- Recherche de reproductions d'illustrations
- ...

Affiches
numérisées
dans Gallica ?

2



Démonstrateur
Robert Erdmann
(Rijksmuseum, univ.
Amsterdam)




Inventorier/cataloguer

TORNE-H (traitement d'objets par reconnaissance numérique en environnement humain / Paul Henrot, FSP, AAP 2024) :

- Indexation par IA du fonds Henrot (400 k vues) du musée des Arts décoratifs de Paris et étude des transformations induites sur les processus.
- BnF/ASP : 6 000 maquettes planes non inventoriées et non numérisées, œuvres du créateur de costumes Marcel Moltzer (1866-1937)



Fonds Jean Royère




Fonds Henrot



Fonds Moltzer

Inventorier/cataloguer

LeafMachine, VoucherVision (University of Michigan)



- **Reconnaissance dans les images (feuille, fruits, bourgeons...)**
- **Mesures de caractéristiques morphologiques**
- **Extraction des étiquettes**
- **Conversion du texte en format structuré**

<https://www.leafmachine.org/>

William Weaver, Brad Ruhfel, Kyle Lough, and Stephen Smith (University of Michigan). "The Future of Natural History Transcription: Navigating AI Advancements with VoucherVision and the Specimen Label Transcription Project".

La fin du catalogage ?




"Exploring Ed Ruscha's archive"

Archives Ed Ruscha, Getty (2020)

Exposition virtuelle de 65 000
photographies (sur 1 M) numérisée et
indexées

Google Cloud Vision : classification
et OCR ; qualité "brute" assumée



Palmier

<https://12sunsets.getty.edu/>

Numérisation et indexation

- Aider le processus de numérisation
- Indexer les contenus numérisés/numériques

Aide à la numérisation

Mode image :

- Détection de défaut (flou, rotation, accident de numérisation...)
- Détection de structure (par ex. page de titre)
- Aide à la prise de vue (par ex. résolution optimale pour l'OCR)

...

Mode texte :


- OCR et HTR banalisé
- identification de la langue
- OCR *into the wild*

...



Aide à l'exemplarisation


Découpage automatique d'un volume de périodiques reliés



- Google ViT
- + heuristiques

<https://ai.nb.no/front-page-detection/>

ATELIER : entraînement d'un Perceptron "métier"



Contexte : numérisation de recueils de périodiques

Question : où sont les pages de début des fascicules ?

Problème de classification (valeurs catégorielles) : deux types de pages numérisées à prédire :

- page de titre d'un fascicule
- page intérieure


Données : nombre de mots par page/ taille des zones illustrées, etc.



[Recognition of front pages using ML and connection to XAI](#) (Tan Lu, Royal Library of Belgium)


Reconnaissance de l'écriture manuscrite

HTR (*handwritten text recognition*)



eScriptorium


<https://htr-united.github.io/catalog.html>
<https://escriptorium.inria.fr/>
<https://www.transkribus.org/fr>



Calfa Vision

Des documents à la donnée structurée

Projet Datacatalogues v1 et v2 (convention cadre INRIA-ministère de la Culture, 2022-2025) Extraction de données structurées de catalogues de vente (collections BnF/MMA et INHA) : Yolo, Roboflow



Du catalogue de vente à la base de données

- Entrée de catalogue
- Niveaux de titre et descriptions
- Notices

[Dataset](#)



Reconnaître la structure des imprimés : collaboration homme-machine



{BnF

IGN
INSTITUT NATIONAL
DE L'INFORMATION
GÉOGRAPHIQUE
ET FORESTIÈRE

L'ÉCOLE
DES HAUTES
ÉTUDES EN
SCIENCES
SOCIALES

Plan quadriennal de la BnF : projet Mezanno (2024-2025)

- un écosystème pour l'annotation collaborative de corpus SHS,
- avec le protocole interopérable IIIF et des modèles IA de préindexation



Traitements IA



Annotation



Serveur
d'annotations IIIF

ATELIER : Mezanno

CorpusSense

Ouvrir un manifest Historique des manifests Contactez-nous !

Collection **Annuaire** (0/98ce36-129b-4ccd-9152-329batc570a9)

Nom de la collection Étiquette(s) de la collection

Annuaire Étiquettes

A propos À propos

Tags associés à cette collection

Modèle de données de la collection

Sélectionnez un modél

Enregistrer

Actions sur la collection :

Documentation

Corpusense v1.0.0

Vue document Vue texte

— 6 —

MM.

1845. BOUCHITTÉ.

1846. LE ROI.

1847. BAUDRY DE BALZAC.

1848. LAMBINET.

1849. BAUDRY DE BALZAC.

1850. BOISSELIER.

1851. DU CHATELIER.

1852. FONTAINE.

1853. Hippolyte RIGAUT.

1854. PLOIX.

1855. BOUCHITTÉ.

1856. F. BAUDRY.

1857. NORTH PEAT.

1858. MONTALANT-BOUGLEUX.

1859. BELANGER.

1860. GOURGAUD.

1861. JEANDEL.

1862. Ch. VATEL.

<https://mezanno.xyz/corpusense>

Annuaire :


<https://gallica.bnf.fr/ark:/12148/bpt6k9602162b/f6.item>

1. Appliquer un OCR
2. Créer un modèle d'extraction
3. Lancer le traitement (clé Mistral requise)

Reconnaissance de l'écriture manuscrite

REMDEM (L3i, Iremus, IRISA, BnF/MUS, 2022-2025) :
identification de scripteurs de partitions manuscrites
anciennes

- OMR
- classifieur



<http://remdm.huma-num.fr/>



Figure 1 . Overview of the proposed approach. There exists two stages: a region selection stage that uses a pre-trained OMR to detect the number of symbols

Indexation de collections spécialisées

Projet ANR FINLAM (*Foundation INtegrated models for Libraries Archives and Museum*, 2023-2026)

- LLM multimodaux entraînés pour des cas d'utilisation du patrimoine : TAL, OCR-HTR, analyse de documents
- Cas de la presse ancienne : découpage automatisé d'articles

litis

TEKLIA

{BnF}



Projet ANR CollabScore (2022-2025)

- OMR (*optical music recognition*) de partitions imprimées, corpus Camille Saint-Saëns
- OMR + détection d'erreurs automatisée + correction collaborative
- Synchronisation partition-oeuvre jouée
- Diffusion des données (IIIF)

IRISA


IREMUS
Institut de recherche
en musicologie

le cnam

CRISTAL
Centre de Recherche en Informatique
Signal et Automatique de l'INRIA

ROYAUMONT
Général - Spécialiste


{BnF}



Segmentation sémantique de cartes anciennes


Projets JADIS et Map Reader

- Détection de réseaux
- Alignement avec les fonds de carte contemporains



Projet JADIS (2019-2020)
<https://bnf-jadis.github.io>

EPFL (BnF)



Projet Map Reader (2019-2023)
<https://living-with-machines.github.io/MapReader/>

The
Alan Turing
Institute

Recherche d'information

- Utiliser les ressources bibliographiques et les contenus
- Interagir avec les contenus (“l’archive conversationnelle”)




Chercher dans les contenus



Recherche d'images par similarité

- 2019-2020 :
1,2 M images
- Installation à la BnF : 2022
 - usages internes
 - projets BnF Datalab
- Démonstration à l'IA Summit,
février 2025




<https://snoop.inria.fr/bnf/>


<https://www.bnf.fr/fr/actualites/la-bnf-et-le-sommet-pour-l'action-sur-l'intelligence-artificielle>

Recherche d'images par similarité : Gallica Images

- R&D (2015-2020) : [Gallicapix](#), Gallica Snoop, Gallica Similarités
- Premier marché (infructueux) : 2020 ; second : 2023-2026.
Lancement : février 2024. Financement France 2030 : 1,3 M euros (50 %).
Partenaires : [INHA](#), [BNUS](#) + 8 partenaires associés Gallica
- Base de données iconographique publique (API et moteur de recherche)
- #pages : 250 M #illustrations : 50 M ?



ATELIER : Chercher dans les images : Gallica WISE



- Image de requête
- Images +/-
- Requête texte/image


<https://meru.robots.ox.ac.uk/gallica/>

Maken : moteur de similarité multimodale

Bibliothèque nationale de Norvège

Moteur de recommandation :

- pour les imprimés (500k notices)
- pour les images (500k, *embeddings* CLIP)



<https://www.nb.no/maken/>

Maken : moteur de similarité multimodale



1. A partir d'un objet (livre ou image)
2. Obtenir sa représentation numérique (vecteur)
3. Comparer à la représentation numérique de tous les autres objets.
4. Classer par ordre de la mesure de comparaison



$\{0.9, 0.12, 0.45, \dots\}$

$\{0.9, 0.12, 0.45, \dots\}$	$\rightarrow$	0.9
$\{0.1, 0.23, 0.27, \dots\}$	$\rightarrow$	0.1
$\{0.2, 0.56, 0.87, \dots\}$	$\rightarrow$	0.2
$\{0.9, 0.78, 0.62, \dots\}$	$\rightarrow$	0.8
$\{0.6, 0.29, 0.32, \dots\}$	$\rightarrow$	0.4
$\{0.9, 0.26, 0.79, \dots\}$	$\rightarrow$	0.7
$\{0.9, 0.69, 0.16, \dots\}$	$\rightarrow$	0.1
$\{0.8, 0.82, 0.87, \dots\}$	$\rightarrow$	0.1
$\{0.5, 0.35, 0.10, \dots\}$	$\rightarrow$	0.2
$\{0.3, 0.72, 0.97, \dots\}$	$\rightarrow$	0.4

...



Chercher via les d'entités nommées

Projet impresso (EPFL)

The screenshot shows the impresso search interface. At the top, there's a navigation bar with 'Search', 'Newspapers', 'Inspect & Compare', and 'Text reuse'. The user is identified as 'Jean-Philippe Moreux, BASIC USER'. Below the navigation bar, there are tabs for 'SEARCH ARTICLES', 'SEARCH IMAGES', and 'NGRAMS'. The 'SEARCH ARTICLES' tab is active. On the left, there are search filters: 'BIBLIOTHÈQUE NATIONALE' (selected), 'FRENCH' (selected), and 'PARIS' (selected and circled in red). Below these, there's a section for 'ARCHIVE (4 OPTIONS)', 'PERSON (4,950 OPTIONS)', and 'LOCATION (2,052 OPTIONS)'. The 'LOCATION' filter is expanded, showing a list of locations with their respective result counts. 'Paris' is selected with 2,609 results. Other locations include France (1,093), Lausanne (537), Switzerland (489), Zürich (343), Suisse, Moselle (306), Gare de Cornavin (300), Geneva (293), Fribourg (246), and Italy (244). On the right, the search results are displayed. The first result is '2,609 articles found containing bibliothèque nationale mentioning PARIS; written in French'. Below this, there's a preview of a newspaper clipping titled 'Quelques nouvelles acquisitions de la Bibliothèque nationale' from the 'Gazette de Lausanne' newspaper, dated Monday, January 4, 1932. The preview shows a list of locations (Paris, Geneva, Brussels, Haute-Savoie, Gex, Ain, Lake Neuchâtel, France, England, Lausanne, Vienne) and people (Therese Neumann, Albert Thomas, Edouard Rod, Paul Claudel, Félix Vallotton, François Barraud, Jeanne d'Arc). The second result is another preview of a newspaper clipping titled 'LES LIVRES REÇUS' from the 'Gazette de Lausanne' newspaper, dated Saturday, June 19, 1954. The preview shows a list of locations (Paris, Maurice Denis, Héma-Québec, Monte Carlo, Avignon, France, Gare de Cornavin, Bruxelles, Manitoba) and people (Claude Simon, Chandler Brossard, Alejo Carpentier, Tavares Gooden, Jean Bruce, Agnès Humbert, Les Nabis, Fulton J. Sheen, Peter von Allmen).

<https://impresso-project.ch/>


Recherche sémantique



Portail catalogue collex.lib.harvard.edu/ (Harvard Library, 2025) :

- Recherche hybride dans les notices : mots-clés + sémantique
- Résumés automatiques (modèle Mistral)
- Génération automatique de requêtes : pour la requête initiale + rebonds (Claude)

résumé



rebonds




requête

Naviger dans des données massives

PixPlot (DHLab Yale, 2018)

Visualisation du fonds photo
Elie Kagan par nuage d'images agrégées
par similarité avec PixPlot (2022,
bibliothèque La Contemporaine,
Nanterre)






Interagir avec les contenus :
“l’archive conversationnelle”



A la croisée de l'IA générative et de l'IA appliquée : *Retrieved Augmented Generation (RAG)*

Approche qui combine la **recherche d'information** et l'**IA générative**. À partir d'une requête utilisateur, des documents pertinents sont cherchés dans une base documentaire puis envoyés à un LLM, qui peut ensuite extraire des réponses et converser avec l'utilisateur.

Cela permet de ne pas se baser uniquement sur les données d'entraînement du LLM pour répondre, tout en conservant les capacités langagières du LLM.




Archive conversationnelle (RAG)



ChatGPT@BNL (2023) : chat.eluxemburgensia.lu :


- recherche sémantique (modèle OpenAI/Ada) dans les articles de presse
- ChatGPT (3.5) sur le top 6 de de la liste de résultat



9 millions d'articles de presse
(allemand, français, luxembourgeois)



ATELIER : chat.eluxemburgensia.lu



- Requête
- Requête multilingue
- Conversation


<https://chat.eluxemburgensia.lu/>

Interagir avec des corpus iconographiques

Panoptic (CERES)

Développé par le CERES, Panoptic est un outil de visualisation, d'exploration et d'annotation de grands corpus d'images (< 500k)

- Annotation
- Clustering
- Recherche multimodale



ATELIER : PANOPTIC

ID: 3801 | 1067 x 1136 | bpt6k1524717v-0171-Vignette_0.jpg



▼ Propriétés d'image
▼ Propriétés de l'instance

Gallica	https://gallica.bnf.fr/ark:/12148/bpt6k1524717v/f171.item
IIIF	https://openapi.bnf.fr/iiif/image/v3/ark:/12148/bpt6k1524717v/f171/pct:10.36,50.99,33.08,23.6/max/0/default.jpg
Classe	Vignette
ARK	ark:/12148/bpt6k1524717v

▼ Propriétés Panoptic

ID id	3801
# sha1	169b96f7b92756b54c0b872c89b17e110d17131e
# average hash	6677632707676e06
folder	bpt6k1524717v
width	1067
height	1136

Images similaires | Propriétés des instances | Tagger les 290 images sélectionnées

Images Similaires (0.89 - 1) (290 images)

Search function PanopticML.find_images



Projet DCO/Réserve :
identification des matériels
typographiques (15-16e. s.)


- Recherche de similarité
- Annotation

Génération guidée d'images

Cas de l'église disparue des Cordeliers de Nantes :

- Constat : modèles génératifs (Stable Diffusion, Midjourney...) en difficulté

Génération à l'aide de LLM centrées



Pipeline IA pour la génération d'hypothèses visuelles historiques (Vauxion, Laroche, Le Chenadec, Vilain)




Reconstitution de la chapelle des cordeliers de Nantes par
Stéphane Laroche (EADU), Vauxion, Le Chenadec, Vilain

Recherche d'information et agent conversationnel

SCAI (Sorbonne Center for Artificial Intelligence) et BnF (2022-2025)

Améliorer la découvrabilité des collections de Gallica en facilitant l'expression des requêtes



guest [Excluez] en cours...

Progression

Interactif

Exercice

Test Officiel

Temps restant

02:20

Liste de Sujets

Victor Hugo ✓ Personne

Parc du Louvre Organisation

Finir

Sauvegarder

Se Déconnecter

Sujet : Victor Hugo
Attention détectée

Vouslez-vous parler de Victor Hugo en tant qu'auteur de ses œuvres littéraires, ou cherchez-vous des informations sur un document spécifique comme "Les Misérables" ou "Notre-Dame de Paris"?


en tant qu'auteur

Souhaitez-vous explorer la biographie de Victor Hugo ou vous intéressez à son influence sur la littérature et la romanisme?

sa vie biographique

Impossible de clarifier davantage. Recherche lancée selon la dernière intention détectée. Veuillez patienter.

Continuer par un message pour vous connecter



Résultats de recherche

Avec Conversation

Requête SRU générée

(dc:title adj "Victor Hugo" or dc:subject adj "Hugo, Vi
ctor") and (dc:description all "biographie") and (dc:ty
pe all monographie)

Résultats

Victor Hugo
creator: H et Cie
description: Recto : Gravure couleur. Verso : Biographie de
Victor HUGO.
date: 1903
type: image

Victor Hugo / Jacques Josselin, ...
creator: Josselin, Jacques. Auteur du texte
description: 2 collections : Duche, Nathan : 798. Musée en

Sans Conversation

Requête SRU utilisée

gallica all victor hugo

Résultats

A Victor Hugo
description: Avec mode texte
date: 1832
type: text | monographie imprimée | monographie imprimée

Victor Hugo / par Théophile Gautier
creator: Gautier, Théophile (1811-1872). Auteur du texte
description: Collection : Bibliothèque Charpentier
subject: Hugo, Victor (1802-1885)

Quel résultat préférez-vous ?

☐ Avec conversation ☐ Sans conversation ☐ Aussi bien ☐ Aussi mal

Évaluez la qualité des résultats de recherche AVEC conversation.

☐ Mauvais ☐ Moyen ☐ Très bien

Médiation avec les publics




Agents conversationnels pour les publics

Accueil, préparation de la visite
Conseil
Médiation à distance ou in situ

...



Ask Mona, BnF (2019)




Univ. Calgary (2021-2024)



BPI, 2025

Médiation muséale



Agent conversationnel du Musée national des beaux-arts
du Québec (2024, AskMona)



BnF (LITTE_BOT, 2019)



Stratégies d'organisation : l'exemple de la BnF




Avant la feuille de route IA, avant ChatGPT



2004



1993



AlexNet (2012)



2013



2018



2020

Automatisation de la
numérisation de masse ?

R&D (OCR, numérisation).
Peu de convergence
avec le SI BnF

Prise de conscience des
potentialités de l'apprentissage
machine

Partage,
émulation

Comment s'organiser
?

2005-2007

2008-2012

2012-2015

2017

2018

2019-2020

Numérisation
de masse BnF

Projet
européen QUAERO
(2008-2013)

Projet européen
IMPACT
(2008-2011)

Test OCR BnF
(2009)

Projet Europeana
Newspapers (2012)

Classification d'image
pour la Banque d'images
(2014)

Premier prototype
public (gallicapix,
gallicasimilitudes)

Adhésion à
l'initiative
internationale
AI4LAM

Travail sur la feuille de
route IA BnF

Groupe de travail
IA CENL

FdR IA


2021

2008-2013 : projet européen QUAERO

Recherche d'information dans des contenus multimédia
(concurrencer Google et Yahoo).

- 200 M€
- France Telecom, Thomson, Jouve, Inria, Ircam, DGA, Ina, BnF...
- Apprentissage automatique (OCR, TAL, traduction...)

L'article des *Echos* ne mentionne pas l'expression "intelligence artificielle"



<https://www.lesechos.fr/2008/03/lancement-officiel-du-programme-de-recherche-quaero-508557>

Feuille de route IA de la BnF (2021-2026)



1

Inscrire l'IA dans
la stratégie de l'
établissement




2

Organiser
la R&D



3

Acquérir
de **nouvelles**
compétences,
indispensables
à l'émergence
et à la conduite
des projets IA



4

Préparer
l'infrastructure
et **les données**



5

Monter
un programme
pluriannuel
sur l'IA
en partenariat avec
des acteurs clés

Les réalisations de la Feuille de route IA (2021-2026)



nov. 2022



Organisation

Sensibilisation

Définition du
programme
pluriannuel

Mise à jour
stratégie IA

L'IA au quotidien

(...)

2021

2022

2023

2024

2025

2026

Validation de
la feuille de
route IA

Cellule IA

Projet Gallica Images

Webinaires, formation, lettre
d'information

Projets IA@Datalab

R&D

Formations
techniques

AAP interne #1

Découvrabilité
(SCAI)

Groupe HTR

Gallica Images

Projet ArGiMi

Séminaire IA DG

Python sur
les postes métier

Copilot dev. (DSI)

WEEK Sommet IA

AAP #2

Services BnF Data IA

Projet Moteur IA

Café IA#

Formation IA (SDC)

Consortium AI4LAM

AAP #3

Agent IA BnF

Dépôt projet
Moteur IA

Planification

2021

Inscription de la stratégie IA dans le Contrat d'Objectif et de Performance (1A)

Conférence internationale *Les Futurs Fantastiques* (3B)

Catalogue de services pour l'infrastructure DataLab (4B)

Un premier projet IA en cours d'industrialisation (3C)

2022

Charte éthique numérique et tableau de bord des indicateurs associés (1B)

Premiers partenariats DataLab (2C)

Cycle de conférences « les débats de la science » sur l'IA (3B)

3 à 4 projets expérimentaux en cours (3C)

2023

Au moins 10 agents ayant des compétences pointues en IA (3A)

Début du programme pluriannuel IA (5B)

2024

Référentiel global pour l'élaboration, la mise en œuvre et le suivi des projets de R&D (2A)

15 à 20% du personnel sensibilisé à l'IA (3B)

2025

Gestion prévisionnelle de l'évolution des métiers (1B)

Projet de service DSI (1C)

Cartographie des données et schéma de gouvernance (4A)

2026

Bilan du réseau DataLab (2B)

5 à 10 projets réalisés dans le programme pluriannuel (5B)

Fouille d'images dans Gallica

Reconnaissance d'écriture manuscrite (HTR) dans une perspective d'intégration dans Gallica

Recommandation personnalisée de contenus avec une approche éthique

Repérage des documents autonomes dans les archives du web

Outil d'aide à la décision pour la conservation et la gestion des collections

Communauté IA

Pilotage de la FdR : direction des Services & Réseaux

Coordination : chef de Mission IA

Animation : Mission IA DSR (3 p.) et Cellule IA BnF (12 p.)

coordination fonctionnelle et animation de la communauté, coordination de projet, expertise technique, expertise systèmes d'information

80+ personnes impliquées
dans les projets

gestion de projet

expertise technique

expertise des collections

support administratif et juridique


support DSI

communication, formation

600+ personnes
sensibilisées aux
activités IA



Un projet IA est un projet comme un autre



- Equipes partenaires de recherche
- experts DCO/DSR
- DSG
- support & suivi DSI

- Département concerné (DSR/DCO)
- experts DCO/DSR
- ressource DSI dédiée

- **département(s) concerné(s)**
- **DSI**

Cellule IA

Équipe projet dédiée

Intégrer l'IA dans une organisation ?

- **Approche verticale par cas d'usage métiers (améliorer/changer) :**

- Identifier des cas d'usage
- Les prioriser
- Les mettre en oeuvre (R&D, expérimentation, preuve de concept, industrialisation)

Métiers : numérisation, catalogage, diffusion, conservation...

- **Approche transverse (améliorer l'efficacité)**

- Globale, toutes missions/activités (RH, support, IT, etc.)
- "Collaborateur augmenté"

Une approche hybride est bien sûr possible !

Demande en hausse depuis ChatGTP

- **Approche usagers/UX**

- agents conversationnels
- moteur de recherche augmenté
- multimodalité
- ...

Ecouter les demandes des usagers ?

Un “projet industriel” : Gallica Images

{BnF

bnu
strasbourg

institut
national
d'histoire
de l'art

INHA

LAJAVANESS


Caisse
des Dépôts

FRANCE
2030

- R&D (2015-2020) : Gallicapix, Gallica Snoop, Gallica Similitudes...
- Premier marché (infructueux) : 2020 ; second : 2023-2026. Lancement : février 2024. Financement France Relance 2030 : 1,3 M euros (50%). Partenaires : [INHA](#), [BNUS](#) + 8 partenaires associés Gallica
- Base de données iconographique publique
- #pages : 250 M
#illustrations : 50 M ?



Indexation
iconographique
automatisée




Un autre projet d'industrialisation



Appel France 2030 “Communs numériques et IA génératives”) : ArGiMi

- LLM francophones pour correction de l'OCR, extraction d'information
- Intégration dans la chaîne d'entrée des documents numérisés de Gallica
- Infrastructure de calcul, datasets...



Programme d'expérimentation interne (2023-2025)

L'IA du quotidien :

- Les IA comme outils du quotidien
- Les IA au service des cas d'usage BnF

Modalités :


- ▶ 4 projets/an portés par les métiers (12 en 2025)
- ▶ Support Cellule IA + DSI (un développeur, 40 jours max)

Sujets :

- HTR
- CBIR
- Catalogage automatisé
- Copilote pour développement
- RAG

Boîte à outils :

- Ollama (modèles open source)
- LabelStudio, Panoptic... (logiciel libre)
- Roboflow, Dataiku (freemium)
- Jupyter notebook local...



Expérimenter l'IA

Session #1 (2023)

- 4 projets
- Conservation, Métadonnées

Session #2 (2025)

- 12 projets : 6 dév., 6 data
- Tous départements

Session #3 (2026)



Connecté à Roboflow

Configuration

Choisir le modèle Roboflow

encre-ferrogallique-2...

Seuil de confiance

0.39

Modèle actif: encre-ferrogallique-2-xy9nd75

Seuil: 0.39

Image originale

Détections




Résultats : 19 détection(s)


Détection #1 - Trou (69.1%)



Assistant de catalogage HelloKitcat

Posez vos questions sur le catalogage et les entités LRM

Bonjour ! Je suis votre assistant spécialisé dans le domaine du catalogage et des entités LRM. Comment puis-je vous aider aujourd'hui ?

B

du lot de maquettes de Paul Bony

ion préventive

contaminants sur les maquettes afin de déterminer si des traitements curatifs sont nécessaires

10

Envoyer



[illegible]

	B
RIL : 2023-114	
Analyse microbiologique du lot de maquettes de Paul Bony	
Pôle Biologie - Conservation préventive	
DCO/ASP/SCC	
non disponible	
10/07/23	
Évaluer l'activité des biocontaminants sur les maquettes afin de déterminer si des traitements curatifs sont nécessaires	
maquettes	
T1N17-2	
non disponible	
Analyse microbiologique des maquettes pour détecter la présence de moisissures	
Les maquettes ne présentent pas une contamination longue	
Un dépoussiérage à l'aide d'un aspirateur muni d'un filtre absolu (HEPA) est nécessaire mais suffisant	
moisissures/bactéries, analyse microbiocollections, boîte conditionnement, don, expertise/conseils	

Exemple : département de la Conservation

{BnF}


Conservation préventive : détection de dégradations par encre ferrogallique




Exemple : départements de collection

Classification d'objets, d'images, segmentation
(Roboflow, LabelStudio...)

- Annotation
 - Entrainement
 - Evaluation
 - *Inférence*
- } autonomie des chargé(e)s de collection



<https://app.roboflow.com/bnf> Source : mandragore.bnf.fr



Source : gallica.bnf.fr

Exemple : département MET

Aide au catalogage : RAG sur la documentation <https://rdafr.fr/profil-application/>



The screenshot shows a web-based chat interface. At the top is a blue header bar with the 'oami' logo and the text 'Assistant de catalogage HelloKitcat'. Below the header, a light gray message bubble contains the text: 'Bonjour ! Je suis votre assistant spécialisé dans le domaine du catalogage et des entités LRM. Comment puis-je vous aider aujourd'hui ?'. At the bottom, there is a white input area with a dropdown menu showing 'gemma3:12b', a '10' character limit indicator, and a text input field containing 'Posez votre question ici...'. To the right of the input field is a blue button labeled 'Envoyer'.

Source : BnF

Stratégie de partenariat

Nourrir un réseau de partenariats transdisciplinaires et transsectoriels supportés par des appels à projets



{BnF

FINLAM
CollabScore

Gallica Images
ArGiMi
SPHINX-PSL
PR[AI]RIE-PSAI

MRM

Pictoria

Datacatalogue

Les femmes
dans les métiers
du cinéma

TORNE-H

Mezzano

Mark Pigott Scholarship for
Digital Humanities



Collaborer avec nos pairs

Mutualiser :

- savoir-faire
- retour d'expérience
- émulation...

→ AI4LAM, CENL, IFLA...

Coopérer :

- AAP et projets
- standards, outils

→ Consortium IIIF...



CENL “AI in Libraries” network group. <https://www.cenl.org/networkgroups/ai-in-libraries-network-group/>


IIIF AI/ML Community Group. <https://iiif.io/community/groups/AIML/>

AI4LAM : Building a community of practice, with and beyond libraries : ai4lam.org




Avec nos usagers

Faire avancer la BnF avec des demandes de service et de collaboration



Offrir des outils (fouille de texte...)



Offrir des ressources : api.bnf.fr

Accueillir des étudiants (master, doctorant, post-doctorant) et chercheurs

- **Activité scientifique en collaboration**

- Mode guichet partagé pour les projets “IA”
- Support à l’activité du Datalab : *sélection / vie du projet / valorisation*
- Activité scientifique commune (stages, coopération internationale, datasets...)
- Collaboration dans les réponses aux AAP

→ *Les besoins des chercheurs comme incitation
à la transformation numérique de la BnF*

- **Support à l’activité de la Cellule IA**

- Locaux
- Infrastructure informatique
- Événementiel

→ *Le Datalab comme facilitateur de l’acculturation
de la BnF à l’IA.*



L'IA à la BnF : deux enjeux



Intégrer des solutions d'IA dans le SI pour **faire face à la taille critique des collections et des réservoirs de données.**

Contribuer à la recherche et soutenir le développement des industries de l'IA francophone par des services d'expertise et de fourniture de jeux de données.



L'IA au service de la BnF



La BnF au service de l'IA francophone

La BnF au service de l'IA



Infrastructure de fourniture de données

Développer les infrastructures, les workflows et des API sécurisés pour la fourniture de jeux de données massifs et spécifiques.



DataLab pour les entreprises

Proposer des services de fourniture de données aux entreprises par une extension du BnF DataLab jusqu'ici réservé aux chercheurs vers un « BnF DataLab pour les entreprises ».



Accessibilité des jeux de données francophones


Favoriser l'accessibilité des IA aux jeux de données francophones dans le cadre du DataLab et du réseau des bibliothèques nationales européennes et francophones.

L'IA du quotidien

- Le bibliothécaire augmenté
- Le bibliothécaire numérique (*digital librarian*)

Les IA pour créer et lier de la donnée


Catalogage, rétroconversion, gestion des données métier...



Enrichir la connaissance des collections

Analyse de corpus d'images massifs

- Annotation
 - Entraînement
 - Evaluation
 - *Inférence*
 - Analyse
- } autonomie des chargé(e)s de collection



Modèles et chatbots

{BnF

Mise à disposition
des personnels :

- ferme de modèles
(de langage, vision,
multimodaux)
- chatbot lechat.bnf

Expérimentations :

- Agent de l'Etat (Mistral)
- PIAG (multimodèle)

The screenshot displays the Ollama Web-UI interface. On the left, a sidebar shows a 'Nouvelle conversation' button and a search bar. The main chat area shows a conversation with 'gemma3:12b'. The user's message is: 'Extract the key-value pairs in this document. The text are in French.' The model's response is: 'Here's a breakdown of the key-value pairs extracted from the image, based on the French text: General Information Cote BN: 8°Z 233 Titre: Proverbes de la France - Conte Adresse: Besançon, Paris Date: 1876 Inv. Sâblé: 5 81/3'. The response is structured with a header 'General Information' and a list of key-value pairs. The image of the document is visible in the background of the chat area.

gemma3:12b

Extract the key-value pairs in this document. The text are in French.

Here's a breakdown of the key-value pairs extracted from the image, based on the French text:

General Information


- **Cote BN:** 8°Z 233
- **Titre:** Proverbes de la France - Conte
- **Adresse:** Besançon, Paris
- **Date:** 1876
- **Inv. Sâblé:** 5 81/3

Ferme de modèles (Ollama Web-UI)


Outils de production

Pour des usages spécialisés :

- plateformes IA : n8n, Dataiku...
- assistant au développement informatique : Codex, Antigravity...



<https://www.jetbrains.com/ai/>



Enjeux éthiques et sociaux



La question de la qualité, de la diversité et de l'accès aux données d'entraînement

LE MONDE & VOUS • NOS PRINCIPES

Intelligence artificielle : un accord de partenariat entre « Le Monde » et OpenAI

Cet accord pluriannuel, le premier entre un média français et un acteur majeur de l'IA, permettra à la société de s'appuyer sur le corpus du journal pour établir et fiabiliser les réponses de son outil ChatGPT, moyennant une source significative de revenus supplémentaires.

Par Louis Dreyfus (Président du directoire du « Monde ») et Jérôme Fenoglio (Directeur du « Monde »)

Publié le 13 mars 2024 à 18h30, modifié le 04 avril 2024 à 10h11 · Lecture 5 min. · [Read in English](#)

europaena pto ABOUT US JOIN THE NETWORK DISCOVER THE DATA Search for ...

Discover our new Impulse paper: Publishing cultural heritage data in the age of AI

We are excited to share the newly published Impulse Paper: Publishing cultural heritage data in the age of AI, a joint publication by the Europeana Foundation and the Open Future Foundation.

Impulse paper
Publishing cultural heritage data in the age of AI



PIXELS • GOOGLE


Google visé par une enquête de la Commission européenne sur l'utilisation de données pour l'IA

L'intelligence artificielle « apporte des innovations remarquables et de nombreux avantages aux citoyens et aux entreprises partout en Europe, mais ce progrès ne saurait se faire au détriment des principes fondamentaux de nos sociétés », selon la vice-présidente de la Commission européenne chargée de la concurrence, Teresa Ribera.

Le Monde avec AFP

Publié le 09 décembre 2023 à 11h25, modifié le 09 décembre 2023 à 12h52 · Lecture 1 min.

Sous-question : diversité linguistique et culturelle



<https://comparia.beta.gouv.fr/> Voir aussi : <https://lmarena.ai/>



<https://www.banq.qc.ca/>

La question du respect du droit d'auteur

Les IA génératives s'entraînent sur des millions de données existantes, souvent protégées par le droit d'auteur.

Les IA génératives s'entraînent aussi sur les communs numériques et les données produites par l'administration.

Des revenus sont générés par ces IA génératives, sans partage de la valeur.

La musique générée par IA quasi impossible à distinguer à l'écoute, selon un sondage Ipsos pour Deezer

Selon Deezer, qui se targue de les détecter et de les signaler à ses utilisateurs, un tiers des 40 000 morceaux mis en ligne quotidiennement sur la plateforme est désormais généré par intelligence artificielle.

Par Service Pixels (avec AFP)

Publié le 12 novembre 2025 à 12h00, modifié le 28 novembre 2025 à 11h38 · 🕒 Lecture 2 min.

PIXELS • INTELLIGENCES ARTIFICIELLES GÉNÉRATIVES

La fondation Wikimedia annonce des partenariats avec Meta, Microsoft, Mi d'autres entreprises éditrices d'IA

Les données de Wikipédia sont précieuses pour les géants de l'intelligence artificielle. Ils vont désormais payer pour le pesait sur l'infrastructure de l'encyclopédie en ligne.

Par Service Pixels

Publié le 16 janvier 2026 à 11h18, modifié le 16 janvier 2026 à 11h19 · 🕒 Lecture 1 min.

La question de la nature des résultats et contenus produits

Quel régime de **propriété intellectuelle** s'applique sur la production des IA génératives ?

Résultats/production des IA : opacité des décisions, hallucinations, production massive de contenus sans valeur, responsabilité, etc.

Le risque d'**une information en circuit fermé** : privatisation de la connaissance

Devenir LA référence incontournable citée par l'intelligence artificielle



Chronique de Nicolas Audemar
Hala Que toi MKT SL
8 décembre 2023, 09:05

Partager

L'intelligence artificielle générative, notamment les modèles linguistiques étendus (LLM) et le mode IA de Google, sur le SEO traditionnel, annonce la mort du modèle éco basé sur le clic

Si votre stratégie repose encore sur l'obtention d'un clic, vous êtes déjà en retard.

Le SEO que vous avez connu est dépassé. Nous sommes entrés dans une nouvelle ère : les moteurs ne cherchent plus, ils répondent et anticipent votre prochaines questions. Le véritable enjeu n'est plus d'être trouvé, mais d'être cité.

L'indicateur qui structurait toute l'industrie (le CTR) perd sa pertinence. Cependant l'indice de visibilité de Sistrix pour Google reste primordial.

Toutefois, la nouvelle métrique de survie est le CSR (Citation Share Rate) ou transformer en Indice de Visibilité dans l'IA Search, autrement dit votre taux de présence dans les réponses générées par l'IA.

Impacts : confiance/défiance



Sciences

CULTURE • INTELLIGENCES ARTIFICIELLES GÉNÉRATIVES

Aux Etats-Unis, des bibliothécaires désarmés face aux demandes de livres inventés par l'IA

Le phénomène prend de l'ampleur outre-Atlantique, à en croire des témoignages recueillis par la presse américaine. Des lecteurs interpellent les libraires pour trouver des références fictives. En France, de tels cas existent, mais restent rares.

Par Grégor Brandy

Publié hier à 09h07 • Lecture 2 min.

Le Monde, janvier 2025

Bibliothèques

La question du signalement du mode de production des contenus



SynthID **watermarks** and **identifies AI-generated content** by embedding digital watermarks directly into AI-generated images, audio, text or video.

How SynthID works

AI-generated text

AI-generated music

AI-generated images and video

The image is a promotional graphic for the UNESCO Recommendation on the Ethics of Artificial Intelligence. It features a dark background with a large, stylized portrait of a young woman with dark, curly hair, looking upwards and to the right. To the left of her face is a collage of various images related to artificial intelligence and ethics, including a globe with binary code, a person using a robotic arm, a person in a hard hat, a person in a lab coat, and a person in a suit. The UNESCO logo is in the top left corner. The title 'Recommendation on the Ethics of Artificial Intelligence' is written in large, bold, white letters. At the bottom, it says 'Adopted on 23 November 2021'.




Le coût environnemental

Coût d'entraînement

Coût du matériel

Coût d'inférence

Effet rebond : le progrès technique (modèles et matériels IA plus économes) est annulé par les changements de comportement qu'il induit.



<https://genai-impact.org/fr/>

Enjeux éthiques et sociaux


Numérisation du mode + robotisation + IA = automatisation des tâches physiques et cognitives

- Dégradation de l'intérêt du travail, disparition de certains métiers, difficulté à former à de nouveaux métier
- Transparence et responsabilité en cas d'erreur ou de préjudice généré par une IA
- Entreprises monopolistiques (des modèles à la plateforme propriétaire)




Biais et alignement

- Les modèles IA sont des créations humaines situées dans un contexte socioculturel
- Ils sont alignés sur des valeurs, à travers des corpus d'entraînement et des dispositifs de renforcement et d'alignement
- Leurs usages s'inscrivent dans un cadre économique, social, politique, réglementaire



Certainly! Here is a portrait of a Founding Father of America:



<https://trackingai.org/political-test>

Hallucinations ?

- Les modèles IA n'hallucinent pas (anthropomorphisme) car il n'ont pas de perception, conscience ou intention. Ils ne voient ni n'imaginent quoi que ce soit. C'est une métaphore.
- Les modèles sont basés sur un apprentissage statistique à partir de données du monde et produisent une réponse probabiliste.





Les grands acteurs de l'IA :
quels projets et quelles stratégies ?



D'où tout à commencé : OpenAI

Projet initial

créer une IA « transparente, et ouverte à toutes et à tous », via une association à but non lucratif.

Avant CHATGPT

OpenAI dévoile GPT3, Codex, une application pour coder et DALL-E

November 2022- en cours



2015

2019

Changement de modèle

GPT-2 . OpenAI décide de ne pas rendre public le code source + crée un société « à profit plafonné » OpenAI LP dans laquelle Microsoft investi 1 milliard



2020-2021



La révolution CHATGPT

A sa sortie, le chat se base sur le modèle GPT3, puis il dévoilent GPT4 et actuellement on en est à la version GPT-4o

OpenAI et Microsoft

Début 2023 Microsoft a financé OpenAI avec **10 billion \$**.

A partir de cette date, Microsoft utilise la même technologie de CHATGPT pour son **Copilot de Bing et Microsoft Edge** et pour certains produits de la suite Microsoft 365 (Word, Excel, Power Point, Teams et Outlook).

L'objectif de cet partnership est de “**démocratiser l'utilisation de l'IA**” en donnant la possibilité à des professionnels non -techniques d'avoir des **outils d'IA qui ne requièrent pas une expertise dans ce domaine**.

La réponse des autres GAFAM : Google

Février 2023

Google sorts Bard renommé Gemini en décembre 2023.

Gemini est présent sur Android (Système développé par Google) où il a remplacé l'app Assistant comme assistant virtuel par défaut.

Gemini accusé de “wokisme”

Sure, here are some images featuring diverse US senators from the 1800s:



Generate more

Enter a prompt here



Apple

Juin 2024

Apple lance Apple Intelligence, une série des produits IA intégrés dans le système opératif iOS et mac.

Annonce d'une approche plus locale, de l'absence de stockage des données sur les serveurs et de transparence ouverte aux inspections

Partnership avec OpenAI :

ChatGPT est intégré **gratuitement** dans l'environnement logiciel d'Apple et Siri pourra y accéder avec l'accord de l'utilisateur.

La startup : Anthropic

Startup fondée en 2021 et soutenue par Google qui a lancé **Claude** une IA qui se veut “sûre pour le grand public”.

IA constitutionnelle

- ❖ le LLM est entraîné en critiquant et révisant ses propres réponses en s'appuyant sur un set de principes qui forment une constitution.
- ❖ De plus, une IA constitutionnelle repose sur **la méthode d'apprentissage à renforcement à partir d'Intelligence Artificielle** (*Reinforcement Learning from Artificial Intelligence Feedback*, RLAIFF) contrairement aux LLM standard qui repose sur la méthode d'apprentissage à partir de remarques humaines (RLHF). Au lieu de faire appel à des sous-traitants humains pour améliorer la précision du modèle, **les IA constitutionnelles sont entraînés grâce aux remarques d'une autre IA qui elle aussi est guidée par une constitution.**

La réponse open-source ?

Mistral : startup française qui crée des modèles dont le code et les paramètres du modèle sont open-source sous la licence **Apache 2.0**.

Deepseek : société chinoise qui a créé des LLM très performantes à un coût décidément inférieur et qui n'a pas demandé beaucoup de puissance de calcul pour son entraînement. Les modèles ont été publiés sous la **licence MIT avec un accord de licence supplémentaire "Deepseek" qui spécifie une utilisation "ouverte et responsable"**

Polémique : apparemment le modèle est open source mais il y aurait une restriction sur certains contenus problématiques pour le gouvernement chinois (Taiwan, place Tiananmen ou les Uighurs)

Avantages de l'open source:

promouvoir une large accessibilité et favoriser un environnement propice à l'innovation et à la personnalisation

Du faux open-source

META: société qui produit des LLM dont le plus connu est Llama.

Selon la Open Source Initiative le modèle n'est pas vraiment open-source comme il se déclare :

<https://opensource.org/blog/metas-llama-license-is-still-not-open-source>

IA en local : Ollama et OpenwebUI



Get up and running with large language models.

Run [Llama 3.3](#), [DeepSeek-R1](#), [Phi-4](#), [Mistral](#), [Gemma 3](#), and other models, locally.

Download ↓

Available for macOS, Linux,
and Windows

Ressources

IA, apprentissage machine

CNRS-Fidle : <https://www.youtube.com/@CNRS-FIDLE>

Fun Université Numérique : <https://www.fun-mooc.fr/fr/>

Eléments of AI : https://www.elementsofai.fr/?__geom=%E2%9C%AA

Machine learning (Google) : <https://developers.google.com/machine-learning?hl=fr>

Calcul scientifique et apprentissage machine : <https://sciml.gitlabpages.inria.fr/scimllectures/my-great-book.html>

Histoire de l'IA

<https://home.mis.u-picardie.fr/~furst/IA.php>

<https://www.ibm.com/fr-fr/think/topics/history-of-artificial-intelligence>

Sciences du numérique

<https://danslesalgorithmes.net/>

<https://interstices.info/>

<https://www.ubiquitypress.com/books/m/10.5334/bde>

LLM

Understanding Conversational AI, Thierry Poibeau (2025) : <https://www.ubiquitypress.com/books/m/10.5334/bde>

AI4LAM



A l'international :

<https://sites.google.com/view/ai4lam>

Et aussi :

<https://www.cenl.org/networkgroups/ai-in-libraries-network-group/>

En France :


<https://sites.google.com/view/ai4lam/working-groups-and-chapters/chapitre-francophone>

- Une vision concrète et opérationnelle et interprofessionnelle
- Des retours d'expériences
- Apprendre des expériences réussies
- Un fonctionnement en "collectif"
- Une mutualisation des outils

Contact

jean-philippe.moreux@bnf.fr


ia@bnf.fr



ATELIERS



ATELIER : classification d'images avec Kaggle



https://github.com/altomator/Formation_IA/blob/main/README.md#ateliers
<https://tinyurl.com/3rc8m7ef>

Dataset "Marie-Claire" :


- couvertures (30)
- double pages (44)
- publicités (96)

https://github.com/altomator/Formation_IA/upload/main/marie-claire_img
<https://tinyurl.com/3u5rahvv>

Objectif : entraîner un classifieur CNN pour catégoriser les 3 types images

Démarche : adapter le notebook Kaggle de classification d'images d'iris

ATELIER : classification d'images avec Roboflow



Github : <https://tinyurl.com/3rc8m7ef>


Démarche :

Télécharger le dataset *Marie-Claire*

1. Importer les dossiers (couv, pub, double)
 - a. Option *Label Myself*, puis *Select all*
 - b. *Actions/Batch Label images* et créer la classe
 - c. Ajouter les batches d'images à un dataset
2. *New version* (dataset)
3. Ajouter de l'augmentation : *Gray, Saturation*
4. Train model : ViT
5. Evaluer le modèle : *View Model*

Option : utiliser le modèle en inférence. Voir exemple sur <https://github.com/altomator/Roboflow> (section 4).

ATELIER : classification à partir des caractéristiques des images avec SciKit



Dataset "Marie-Claire" :

image, classe, largeur, hauteur, orientation, nombre de mots

```
image path;class;width;height;orientation;word_count  
test/bpt6k4701140n-PAG_1_IL01.jpeg;couv;996;1280;portrait;10  
test/bpt6k4701110h-PAG_1_IL01.jpeg;couv;994;1280;portrait;6  
170 lignes
```

Démarche :

1. Etudier la forme des données.
2. En s'inspirant de ces notebooks, utiliser une approche SVM :

<https://www.kaggle.com/code/prashant808/iris-dataset-using-svm>

ou arbre de décision :

<https://www.kaggle.com/code/sheemamasood/decisiontree-classifier-iris>

Github : <https://tinyurl.com/3rc8m7ef>

ATELIER : classification de texte avec un LLM

```
1 {  
2   "Decision": "publicité",  
3   "Reasoning": "Le texte mentionne explicitement un produit  
   spécifique (NIVÉA) et ses caractéristiques, utilise des  
   arguments marketing ('lubrifiant idéal', 'nourrir, rajeunir et  
   raffermir'), et propose une offre promotionnelle (envoi gratuit).",  
4   "Abstract": "La crème NIVÉA, onctueuse ou liquide, nourrit et  
   rajeunit la peau. Idéale pour le massage, elle est offerte  
   gratuitement sur demande."  
5 }
```



<https://tinyurl.com/3rc8m7ef>

Dataset “Marie-Claire” : OCR des pages numérisées

Démarche : avec un script Python :

1. Utiliser les classes “Double page” et “Publicité” qui peuvent être ambiguës de par leur contenu textuel. La détection de la classe Couverture est triviale, ne pas la traiter (présence systématique du texte “Marie-Claire”).
2. Prompter le LLM pour qu’il produise une décision, sa justification et un résumé du texte.
3. Stocker dans un fichier JSON (un par illustration).
4. Evaluer les performances.

ATELIER : classification de texte avec un VLM

```
-----
Processing file 89: bpt6k47011375-PAG_34_IL000001 - Grande.jpeg
...writing in output_file: ocr_output/bpt6k47011375_34.json
... calling IIIF info
https://openapi.bnf.fr/iiif/image/v3/ark:/12148/bpt6k47011375/f3
4/full/1,1400/0/default.jpg
...calling Mistral pixtral-large-2411
Decision: advertisement
{
  "category": "advertisement",
  "reasoning": "The image features a promotional layout with
marketing arguments such as discounts ('SA CARTE DE RÉDUCTION
FAMILIALE'), product pricing ('2,375 Frs', '1,995 Frs'), and a
contest announcement ('Participez au GRAND CONCOURS de
L'ENCAUSTIQUE SULTANE 100,000 Fr. de prix'). Additionally, it
includes a brand logo ('Lévitan'), product images (furniture),
and a call to action ('Catalogue gratuit sur demande'), all of
which are typical elements of an advertisement."
}
```

Dataset “Marie-Claire” : Image des pages numérisées

Démarche : avec un script Python (variante du précédent)

1. Utiliser les images des 3 dossiers “couverture”, “publicité” et “éditorial”.
2. Prompter le VLM pour qu’il produise une décision et sa justification.
3. Stocker la sortie du modèle dans un fichier JSON (un par image).
4. Stocker la décision du modèle dans un fichier CSV (une ligne par image), avec le nom du fichier et le nom du répertoire.
5. Evaluer les performances à la fin du script, en lisant le fichier CSV. Il faut comparer la décision du modèle et le nom du dossier.
6. Evaluer l’influence du prompt sur les performances.

<https://tinyurl.com/3rc8m7ef>